



ONDOKUZ MAYIS ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**MR GÖRÜNTÜLERİ KULLANILARAK DERİN ÖĞRENME
YÖNTEMLERİYLE ALZHEİMER HASTALIĞININ
SINIFLANDIRILMASI
PROJE RAPORU**

GİZEM DÜZDAŞI

AYŞENUR EŞSİZ

GANİME ZEYNEP GÜLMEZ

Danışman

DR. ÖĞR.ÜYESİ DURMUŞ ÖZKAN ŞAHİN

MAYIS, 2025

TEŞEKKÜR

Çalışmamıza katkı sağlayan Ondokuz Mayıs Üniversitesi'ne ve Sayın Durmuş Özkan Şahin hocamıza teşekkür ederiz.

Ö Z E T

Alzheimer hastalığı, beyin hücrelerinin ölümüne bağlı olarak hafıza kaybı, bunama ve genel anlamda bilişsel fonksiyonların azalmasına neden olan bir demans türü olarak nitelendirilmektedir. Tedavisi mümkün değildir. Ancak erken teşhisle ilerlemesinin önüne geçilebilmektedir. Çalışmada Alzheimer sınıflandırma yöntemleri ile ilgili literatür araştırmasına ve güncel problem çözümlerine değinilmiştir. Kullanılan veri setinde sırasıyla 896 hafif demans, 64 orta derece demans, 3200 demans olmayan ve 2240 çok hafif demans Manyetik Rezonans - Magnetic Resonance (**MR**) görüntüsü bulunmaktadır. Bu veri setine görüntü boyutlandırma ve veri artırma ön işleme adımları yapılmıştır. **MR** görüntüleri, ön işleme aşamasında iyileştirilerek sınıflandırmayı belirlemede etkin sonuçlar alınabilmektedir. Sınıflandırmada Evrişimsel Sinir Ağı - Convolutional Neural Network (**CNN**) ve alt mimarisi olan Kalan Ağ - Residual Network (**ResNet**)-50, Görsel Geometri Grubu - Visual Geometry Group (**VGG**)-16, **VGG**-19, Densely Connected Convolutional Network (**DenseNet**)-121, MobileNet-V2 ve Efficient Neural Network (**EfficientNet**)-B0 kullanılmıştır. Performansını değerlendirmek için ise doğruluk, duyarlılık, kesinlik ve F1-Skoru metrikleri kullanılmıştır.

İÇİNDEKİLER

I GİRİŞ

1	AMAÇ	2
2	LİTERATÜR ÖZETİ	3
2.1	MR Literatür Özeti	3

II MATERYAL

3	MATERYAL	18
3.1	Kullanılan Programlama Dili ve Ortam	18
3.2	Kullanılan Veri Kümesi	19

III YÖNTEM

4	YÖNTEM	22
4.1	Veri Ön İşleme	23
4.1.1	Veri Artırma	23
4.1.2	Görüntü Boyutlandırma	24
4.2	Sınıflandırma	25
4.2.1	CNN	26
4.2.2	Transfer Öğrenme Mimarileri	28
4.3	Performans Metrikleri ile Değerlendirme	31

IV SONUÇ

5 SONUÇ	34
5.1 Transfer Öğrenme Modellerinde Optimizasyonların Sınıflandırma Başarı- mına Etkisi	34
5.2 CNN’de Farklı Mimari ve Optimizasyonların Sınıflandırma Başarımına Etkisi	40
5.3 Önceki Çalışmalar ile Kıyaslama	44
5.4 Sonuç ve Yorum	45
KAYNAKÇA	48

ŞEKİLLER LİSTESİ

1	Örnek MR Görüntüleri	20
2	Metodoloji	22
3	Artırılmış Veri Setinden Örnek Görüntüler	24
4	Optimizasyonların Öğrenme Oranları	25
5	CNN Model Mimarisi	27
6	Transfer Öğrenme Model Mimarisi	29
7	Karmaşıklık Matrisi	31
8	Efficient-B0 Adadelta Optimizasyonu Kayıp ve Doğruluk Grafikleri	39
9	Efficient-B0 Adadelta Optimizasyonu Karmaşıklık Matrisi	39
10	CNN (32x32) - Nadam Doğruluk ve Kayıp Grafikleri	43
11	CNN (32x32) - Nadam Karmaşıklık Matrisi	43

ÇİZELGELER LİSTESİ

1	MR Literatür Özeti	15
2	Veri Seti Veri Dağılımı	19
3	80-20 Veri Setinin Sınıflara Göre Dağılımı	24
4	70-30 Veri Setinin Sınıflara Göre Dağılımı	24
5	Model Parametreleri	26
6	70-30 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (1)	35
7	70-30 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (2)	35
8	80-20 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (1)	36
9	80-20 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (2)	36
10	70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonla- rın Transfer öğrenme Yöntemlerindeki Başarımı (1)	37
11	70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonla- rın Transfer öğrenme Yöntemlerindeki Başarımı (2)	37
12	80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonla- rın Transfer öğrenme Yöntemlerindeki Başarımı (1)	38

13	80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (2)	38
14	70-30 Oranında Bölünmüş Orijinal Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı	41
15	80-20 Oranında Bölünmüş Orijinal Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı	41
16	70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı	42
17	80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı	42
18	Literatürle Başarım Karşılaştırılması	45

KISALTMALAR LİSTESİ

AD Alzheimer Hastası - Alzheimer Disease

Adam Uyarlanabilir Moment Tahmini - Adaptive Moment Estimation

Adagrad Uyarlanabilir Gradyan Algoritması - Adaptive Gradient Algorithm

ADASYN Uyarlanabilir Sentetik Örneklem Yaklaşımı - Adaptive Synthetic Sampling
Method

ADNI Alzheimer Hastalığı Nörogörüntüleme Girişimi - Alzheimer's Disease Neuroimaging
Initiative

ANN Yapay Sinir Ağı - Artificial Neural Network

AUC Eğri Altındaki Alan - Area Under the Curve

CLAHE Kontrast Sınırlı Uyarlanabilir Histogram Eşitleme - Contrast Limited Adaptive
Histogram Equalization

CN Bilişsel Olarak Normal - Cognitively Normal

CNN Evrişimsel Sinir Ağı - Convolutional Neural Network

CPC Olasılık Katsayılarını Değiştirme - Changing Probability Coefficients

DenseNet Densely Connected Convolutional Network

DL Derin Öğrenme - Deep Learning

DNN Derin Sinir Ağı - Deep Neural Network

DT Karar Ağacı - Decision Tree

DTL Derin Transfer Öğrenimi - Deep Transfer Learning

EfficientNet Efficient Neural Network

EHR Elektronik Sağlık Kayıtları

Faster R-CNN Hızlı Bölgesel CNN - Faster Region CNN

FP Yanlış Pozitif - False Positive

GLMC Gri Seviye Eş-oluşum Matris - Gray level Co-occurrence Matrix

GNB Gauss Naive Bayes - Gaussian Naive Bayes

GNN Graf Sinir Ağları - Graph Neural Network

GRU Kapılı Tekrarlayan Birim - Gated Recurrent Unit

HOG Yönlendirilmiş Gradyanların Histogramı - Histogram of Oriented Gradients

ID Yinelemeli Dikotomizer - Iterative Dichotomiser

KNN K-En Yakın Komşu - K-Nearest Neighbors

LDA Doğrusal Ayrım Analizi - Linear Discriminant Analysis

LR Lojistik Regresyon - Logistic Regression

LSTM Uzun Kısa Süreli Bellek - Long Short Term Memory

MCC Matthew's Korelasyon Katsayısı - Matthew's Correlation Coefficient

MCI Hafif Bilişsel Bozukluk - Mild Cognitive Impairment

ML Makine Öğrenmesi - Machine Learning

MLP Çok Katmanlı Algılayıcı - Multilayer Perceptron

MR Manyetik Rezonans - Magnetic Resonance

NACC Ulusal Alzheimer Koordinasyon Merkezi - National Alzheimer's Coordination Center

Nadam Nesterov Hızlandırılmış Adam - Nesterov Accelerated Adam

NB Naive Bayes

OASIS Açık Erişimli Görüntüleme Çalışmaları Serisi - Open Access Series of Imaging Studies

PCA Temel Bileşen Analizi - Principal Component Analysis

PET Pozitron Emisyon Tomografisi - Positron Emission Tomography

PIL Python Imaging Library

RAVLT Rey İşitsel Sözlü Öğrenme Testi - Rey Auditory Verbal Learning Test

RBF Radyal Temel Fonksiyonu - Radial Basis Function

ReLU Rektifiye Lineer Ünite - Rectified Linear Unit

ResNet Kalan Ağ - Residual Network

RF Rastgele Orman - Random Forest

RMSprop Ortalama Karekök Yayılımı - Root Mean Square Propagation

SGD Stokastik Gradyan İnişi - Stochastic Gradient Descent

SNP Tek Nükleotid Polimorfizmi

SSD Tek Adımda Çoklu Kutu Dedektörü - Single Shot Multibox Detector

SMOTE Sentetik Azınlık Aşırı Örnekleme Tekniği - Synthetic Minority Over Sampling
Technique

SVM Destek Vektör Makinesi - Support Vector Machine

TP Doğru Pozitif - True Positive

VGG Görsel Geometri Grubu - Visual Geometry Group

XGB Aşırı Gradyan Artırma - eXtreme Gradient Boosting

BÖLÜM: İ

GİRİŞ

A M A Ç

Alzheimer hastalığı, bilişsel ve nörolojik işlevlerin kaybına yol açan ve geri dönüşü olmayan bir nörodejeneratif hastalıktır. Tedavisi mümkün olmadığı için hastalığın erken teşhisi ve ilerleyişinin yavaşlatılması büyük önem taşır. Dünya genelinde 47 milyondan fazla kişi Alzheimer hastalığı ile yaşamaktadır. İlerleyen yıllarda bu sayının daha da artması öngörülmektedir. Hastalığın teşhisinde MR görüntüleri yaygın olarak kullanılmaktadır. Bu doğrultuda geliştirilen model ve yöntemlerin; klinik alanda doktorlara karar destek sistemi olarak yardımcı olması, sağlık bilişimi ve tıp mühendisliği gibi disiplinler arası çalışmalara katkı sunması ve ileride daha hızlı, daha doğru ve daha güvenilir tanı sistemlerinin geliştirilmesine zemin hazırlaması hedeflenmektedir. Bu çalışmada MR görüntüleri kullanılarak Alzheimer hastalığının erken teşhisini sağlamak için Derin Öğrenme - Deep Learning (DL) yöntemleriyle sınıflandırılması amaçlanmıştır.

LİTERATÜR ÖZETİ

Alzheimer hastalığının sınıflandırılması için veri seti olarak **MR** görüntülerini kullanan yaklaşık 35 tane çalışma incelenmiştir. Bölüm 2.1’de bu çalışmaların özetlerine yer verilmiştir.

2.1 *MR Literatür Özeti*

Dasu vd. halka açık veri seti olan beyin **MR** görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [1]. Veri seti, orijinal veri ve eğitilmiş veri olarak ikiye ayrılmış ve yaklaşık 40 bin görüntü içermektedir. Çalışmada eğitilmiş veri seti kullanılmış olup sınıflandırması şu şekildedir: Hafif demans (8960 görüntü), orta dereceli demans (6464 görüntü), demans olmayan (9600 görüntü) ve çok hafif demans (8960 görüntü). Görüntü ön işleme aşamasında Kontrast Sınırlı Uyarlanabilir Histogram Eşitleme - Contrast Limited Adaptive Histogram Equalization (**CLAHE**) yöntemiyle kontrast iyileştirme yapılmış, Otsu yöntemiyle de kafatası çıkarma işlemi gerçekleştirilmiştir. Özellik çıkarımı için Gri Seviye Eş-oluşum Matris - Gray level Co-occurrence Matrix (**GLMC**) yöntemi kullanılmış ve kontrast, enerji, korelasyon gibi özellikler elde edilmiştir. Sınıflandırmada Destek Vektör Makinesi - Support Vector Machine (**SVM**), K-En Yakın Komşu - K-Nearest Neighbors (**KNN**)

ve Karar Ağacı - Decision Tree (DT) algoritmaları bir arada kullanılmış, model performansı karışıklık matrisi üzerinden duyarlılık, özgüllük, doğruluk gibi metriklerle değerlendirilmiştir. Test verilerinde %95 doğruluk oranı elde edilmiştir.

Sertkaya vd. yaptıkları çalışmada farklı açılardaki ve sabit yoğunluktaki beyin MR görüntülerine gradyan filtresi uygulayarak çeşitli CNN modellerinin üzerindeki performansını değerlendirmiştir [2]. Veri seti; Hafif Bilişsel Bozukluk - Mild Cognitive Impairment (MCI) (507 görüntü), Bilişsel Olarak Normal - Cognitively Normal (CN) (489 görüntü) ve Alzheimer Hastası - Alzheimer Disease (AD) (459 görüntü) olmak üzere 3'e ayrılmıştır. Çalışma orijinal veriler ve gradyan filtresi uygulanmış veriler kullanılarak iki şekilde yapılmıştır. Çalışma sonucunda DenseNet201 modelinin hem orijinal (%97.94) hem de gradyan filtresi uygulanmış verilerde (%98.63) en iyi sonuçları verdiği gözlemlenmiştir. Çalışma sonucunda gradyan tabanlı ön işleme yönteminin modellerin performansını artırdığı tespit edilmiştir.

Das vd. tarafından Alzheimer hastalığı sınıflandırması için Derin Transfer Öğrenimi - Deep Transfer Learning (DTL) modellerinin karşılaştırması yapılmıştır [3]. Veri seti olarak eğitilmiş veri ve test verisi olarak ikiye ayrılmış ve bunlar da çok hafif demans (2240 görüntü), MCI (896 görüntü), orta düzey bilişsel bozukluk (64 görüntü) ve CN (3200 görüntü) olmak üzere toplamda dört farklı sınıfa ayrılmış 6400 MR görüntüsü kullanılmıştır. Veri ön işleme aşamasında çoğunluk sınıfını göz önünde bulundurarak veri artırımı yapmak için Uyarlanabilir Sentetik Örneklem Yaklaşımı - Adaptive Synthetic Sampling Method (ADASYN) kullanılmıştır. Sınıflandırma aşamasında VGG-19, ResNet-50, Xception ve Inception-v3 gibi mevcut CNN modelleri kullanılmıştır. Sınıflandırma performansının değerlendirilmesi için Matthew's Korelasyon Katsayısı - Matthew's Correlation Coefficient (MCC) ve dengeli doğruluk skoru kullanılmış ve bu ölçütler sayesinde modellerin güçlü ve zayıf yönleri belirlenmiştir. Çalışma sonucunda Uyarlanabilir Moment Tahmini - Adaptive Moment Estimation (Adam) optimi-

zasyon yöntemiyle eğitim sağlandığında VGG modelinin dengeli doğruluk skoru ve MCC açısından diğer modellerden daha iyi sonuçlar elde ettiği belirtilmiştir.

Patil vd. Kaggle platformundan alınmış olan beyin MR görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [4]. Veri seti; sağlıklı, hafif demans, orta dereceli demans, demanslı olmak üzere dört sınıfa ayrılmıştır. Her sınıfta 50 denek kullanılmıştır. Model TensorFlow çerçevesinde geliştirilmiş ve Rektifiye Lineer Ünite - Rectified Linear Unit (ReLU) aktivasyonu, evrişim katmanları, maksimum havuzlama ve bırakma katmanları gibi teknikler kullanılarak optimize edilmiştir. Sınıflandırmak için CNN ve MobilNet V2 gibi CNN modelleri kullanılmıştır. En yüksek sınıflandırma oranı özgüllük metriği ve CNN modeli ile demanslı sınıfında %96.13 olarak elde edilmiştir.

Mahmood vd. tarafından yapılan çalışmada, Alzheimer hastalığının daha iyi sınıflandırılması için görüntü işleme ve çok sınıflı bir sinir ağı kullanılmıştır [5]. İlk olarak yüksek boyutlu MR görüntülerine Temel Bileşen Analizi - Principal Component Analysis (PCA) uygulanarak boyut indirgeme işlemi yapılmıştır. PCA'dan elde edilen indirgenmiş boyutları Alzheimer hastalığının ilerleyişine göre kategorize etmek için çok sınıflı bir sinir ağı kullanılmıştır. Sinir ağının eğitimi için Açık Erişimli Görüntüleme Çalışmaları Serisi - Open Access Series of Imaging Studies (OASIS) MR veritabanından elde edilen Alzheimer tanısı konulmuş 230 bireye ait MR görüntüsü kullanılmıştır. Daha sonra, eğitilmiş sinir ağı OASIS veritabanı tarafından sağlanan toplam 457 MR görüntüsü üzerinde test edilmiştir. Sonuç olarak %89.92 doğruluk oranı elde edilmiştir.

Salunkhe vd. tarafından yapılan çalışmada, 234 denekten alınan MR görüntüleri kullanılmıştır [6]. Bu veriler, 119 AD ve 115 CN bireyden toplanmıştır. Toplanan verilerden doku özelliklerini çıkarmak için GLMC kullanılmıştır. Türetilen dokusal parametreler, Rastgele

Orman - Random Forest (RF), DT ve SVM algoritmaları ile sınıflandırılmıştır. En yüksek doğruluk oranı %90.2 ile RF olmuştur.

Alghamedy vd. tarafından yapılan çalışmada, OASIS veri seti kullanılarak Alzheimer hastalığının sınıflandırılması amaçlanmıştır [7]. Bu veri seti 416 örnek içermektedir. İlk olarak elde edilen MR görüntülerindeki gürültü ve kontrast sorunları giderilmiştir. Bu işlem için CLAHE algoritması kullanılmıştır. Görüntüler, k-means algoritması ile segmentlere ayrılmıştır. Faydalı özellikler, PCA algoritması ile çıkarılmıştır. Son aşamada, görüntüler Makine Öğrenmesi - Machine Learning (ML) algoritmaları kullanılarak sınıflandırılmıştır. Veri sınıflandırma için kullanılan algoritmalar arasında SVM-Radyal Temel Fonksiyonu - Radial Basis Function (RBF), Yapay Sinir Ağı - Artificial Neural Network (ANN) ve Yinelemeli Dikotomizer - Iterative Dichotomiser (ID)-3 yer almaktadır. Sonuçlara göre: SVM-RBF, Alzheimer'ın sınıflandırılmasında en yüksek doğruluğu %99 oranında sağlamıştır.

Kumar vd. tarafından yapılan çalışmada Alzheimer hastalığının sınıflandırılması için yaklaşık 50 bin MR görüntüsü kullanılmıştır [8]. Bu MR görüntülerinden Yönlendirilmiş Gradyanların Histogramı - Histogram of Oriented Gradients (HOG) yöntemiyle özellik çıkarımı yapılmıştır. Çıkarılan özellikler ML, DL ve transfer öğrenme yöntemlerinde kullanılmıştır. Modeller, doğruluk, kesinlik, geri çağırma ve F1 skoru gibi metriklerle değerlendirilmiştir. ML kısmında, SVM, RF, Lojistik Regresyon - Logistic Regression (LR) ve DT kullanılmıştır. DL kısmında CNN kullanılmıştır. Transfer öğrenme ise %91 doğrulukla en yüksek sonucu vermiştir.

Prasetyo halka açık veri seti olan ImageNet'ten aldığı beyin MR görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [9]. Veri seti; AD, MCI ve CN olmak üzere 3 sınıfa ayrılmıştır. Her sınıfta sırasıyla 1124, 2590 ve 1440 görüntü bulunmaktadır. Veri seti, sırasıyla %80, %10 ve %10 oranlarıyla eğitim, doğrulama ve test alt kümelerine

bölünmüştür. Bu şekilde etkili model eğitimi, doğrulama ve değerlendirme için yeterli veri sağlanmıştır. Modelleme aşaması için, Xception, InceptionV3, VGG-16, VGG-19 ve MobileNet dahil olmak üzere önceden eğitilmiş CNN mimarileri kullanılmıştır. En yüksek sınıflandırma oranı VGG-19 modelinin ince ayar aşamasında doğruluk metriğine göre %100 olarak elde edilmiştir.

Uysal vd. halka açık veri seti olan Alzheimer Hastalığı Nörogörüntüleme Girişimi - Alzheimer's Disease Neuroimaging Initiative (ADNI)'den aldığı beyin MR görüntülerini kullanarak sınıflandırma algoritmalarının karşılaştırmalı tanı performansını ölçmüştür [10]. Veri seti; AD, MCI, CN olmak üzere 3 sınıfa ayrılmıştır. Her sınıfta sırasıyla 159, 217 ve 109 birey bulunmaktadır. Veriler %66.6 eğitim, %33.3 test seti olarak ayrılmıştır. Sınıflandırmak için LR, KNN, SVM, DT, RF, Gauss Naive Bayes - Gaussian Naive Bayes (GNB) algoritmaları kullanılmıştır. En iyi sonuç GNB algoritması ve özgüllük metriği ile %95 oranında hesaplanmıştır.

Veena vd. OASIS'ten aldığı MR görüntülerini kullanarak Alzheimer hastalığının erken teşhisi için etkili ve doğru bir ML modeli geliştirmiştir [11]. Veri seti; demans olmayan, demanslı ve demansa ilerleyen olmak üzere 3 sınıfa ayrılmıştır. Her sınıfta sırasıyla 72, 64 ve 14 birey bulunmaktadır. Sınıflandırmak için LR, SVM, DT, RF, AdaBoost algoritmaları kullanılmıştır. En iyi sonuç AdaBoost ve RF'nin beraber kullanıldığı sınıflandırmada doğruluk metriği ile %84 oranında hesaplanmıştır.

Demir halka açık veri seti olan ImageNet'ten aldığı beyin MR görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [12]. Veri seti; sağlıklı, çok az derece AD, az derece AD ve orta derece AD olmak üzere dört sınıfa ayrılmış toplam 6400 görüntüden oluşmaktadır. MobileNetV2 ve VGG-16 modelleri kullanılarak öznetelik çıkarılmıştır. İki modelden elde edilen öznetelikler birleştirilerek 5096 boyutlu öznetelik seti oluşturulmuştur.

ReliefF algoritması kullanılarak ayırt ediciliği en yüksek 250 öznitelik çıkarılmıştır. Sınıflandırmak için **DT**, Doğrusal Ayırım Analizi - Linear Discriminant Analysis (**LDA**), **SVM**, **KNN** algoritmaları kullanılmıştır. En iyi sonuç **KNN** sınıflandırma algoritması ve duyarlılık metriği ile %94.9 oranında hesaplanmıştır.

Oishi vd. Japon **ADNI** adlı halka açık veri setinden elde edilen beyin **MR** görüntülerini kullanarak **AD** ve **CN** bireyler arasında sınıflandırma yapmıştır [13]. Veri seti; **AD** ve **CN** olarak iki sınıfa ayrılmıştır. Her iki sınıfta da 10 birey bulunmaktadır. Deformasyon alanından türetilen Jacobian determinanı ile bir beyin bölgesinin hacminin ne kadar değiştiği ölçülmüştür. Olasılık Katsayılarını Değiştirme - Changing Probability Coefficients (**CPC**) yöntemi ile özellik çıkarılmıştır. Sınıflandırmak için Gauss çekirdeği ile **SVM** kullanılmıştır. En iyi sonuç bu iki sınıflandırma algoritması ve duyarlılık metriği ile %94.9 oranında hesaplanmıştır.

Adhora vd. Kaggle platformundan alınmış olan **MR** görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [14]. Veri seti; sağlıklı, çok hafif demans, hafif demans, orta demans olmak üzere 4 sınıfa ayrılmıştır. Her sınıfta sırasıyla 179, 12, 620, 448 denek ve toplamda 6400 görüntü kullanılmıştır. Veriler %80 eğitim, %20 test seti olarak ayrılmıştır. Dengesiz veri seti, Sentetik Azınlık Aşırı Örnekleme Tekniği - Synthetic Minority Over Sampling Technique (**SMOTE**) yöntemiyle dengelenmiştir. Sınıflandırmak için **CNN**, InceptionV3 ve ResNet-50 algoritmaları kullanılmıştır. InceptionV3 ve ResNet-50 algoritmalarının beraber kullanıldığı sınıflandırmada duyarlılık metriğine göre %95 başarı oranı ile en yüksek sonuç elde edilmiştir.

Bharath M. vd. halka açık veri seti olan beyin **MR** görüntülerini kullanarak Alzheimer hastalığının farklı evrelerini sınıflandırmıştır [15]. Veri seti; sağlıklı, çok hafif demans, hafif demans, orta demans olmak üzere 4 sınıfa ayrılmıştır. Her sınıfta sırasıyla 3200, 2240, 896 ve 64 görüntü bulunmaktadır. Sınıflandırmak için **LDA**, **SVM**, **VGG-16**, **EfficientNet-B0**

algoritmaları kullanılmıştır. En iyi sonuç SVM sınıflandırma algoritması ve doğruluk metriği ile %94.9 oranında hesaplanmıştır.

R. Das vd. Alzheimer hastalığının erken teşhisinde hacimsel analiz ve derin öğrenme yöntemlerinin etkinliğini göstermiştir [16]. Veri seti olarak, sağlıklı ve hasta bireylerden alınan toplamda 135 MR görüntüsü (100 eğitim, 35 test) kullanılmıştır. Veri ön işleme aşamasında, hipokampus bölgesini hassas bir şekilde ayırmak için 3D-UNet mimarisi kullanılmıştır. Model, MR görüntülerindeki hipokampal yapıyı segmentleyerek her bireyin sol ve sağ hemisferlerine ait hacimleri hesaplamıştır. Daha sonra, hipokampus hacmine dayalı olarak Alzheimer aşamalarının belirlenmesi için eşik değerleri kullanılmıştır. Sınıflandırma performansını değerlendirmek için Doğru Pozitif - True Positive (TP), Yanlış Pozitif - False Positive (FP) gibi metriklerle desteklenen doğruluk ve F1-Skor gibi ölçütler kullanılmıştır. Çalışma sonucunda, segmentasyon doğruluğu %93, sınıflandırma doğruluğu ise kişiye göre %91, hemisfere göre %88 olarak elde edilmiştir. Ayrıca, mevcut eşik değerlerinin ayarlanmasıyla ve VGG-16 gibi modellerle birleştirildiğinde performansın daha da artırılacağı önerilmiştir.

Jayanthi vd. Alzheimer hastalığının teşhisi için derin öğrenmeye dayalı bir yöntem geliştirmiştir [17]. Veri seti olarak Kaggle'dan alınan ve farklı hastalık sınıflarına ait çok hafif demans (2240 görüntü), MCI (896 görüntü), orta düzey bilişsel bozukluk (64 görüntü) ve CN (3200 görüntü) olmak üzere toplam 6400 MR görüntüsü kullanılmıştır. Veri ön işleme aşamasında, veri seti dengelenmiş, veri artırımı gerçekleştirilmiş ve görüntüler 224x224 piksel boyutunda yeniden boyutlandırılmıştır. Eğitim süreci için veri seti %70 eğitim, %10 doğrulama ve %20 test oranlarında bölünmüştür. Sınıflandırma, VGG-16 mimarisine dayalı bir modelle gerçekleştirilmiştir. Model, derin öğrenme katmanları arasında evrişim, max-pooling, toplu normalizasyon, tam bağlı katmanlar ve softmax aktivasyon işlevini içermektedir. Eğitim

süreci boyunca Adamax optimizasyon yöntemi ve çapraz entropi kayıp fonksiyonu kullanılmıştır. Modelin performansı; doğruluk, hassasiyet, geri çağırma ve F1 skoru gibi metriklerle değerlendirilmiştir. Model, test verisi üzerinde %98.82 doğruluk, %99.40 hassasiyet, %97 geri çağırma ve %98.22 F1 skoru elde etmiştir.

Mamun vd. Alzheimer hastalığının teşhisi için dört farklı DL modeli (CNN, ResNet101, DenseNet-121 ve VGG-16) kullanarak bir çalışma gerçekleştirmiştir [18]. Çalışmada, Kaggle'dan elde edilen 6219 MR görüntüsü kullanılmış ve veri seti çeşitli derecelerde demanslı ve demanslı olmayan beyin görüntülerini içermektedir. Veri ön işleme aşamasında, görüntüler yeniden boyutlandırılmış, gürültüler temizlenmiş, kenar yumuşatma uygulanmış ve görüntü segmentasyonu gerçekleştirilmiştir. Veri seti eğitim, doğrulama ve test aşamaları için sırasıyla %70, %15 ve %15 oranında bölünmüştür. CNN modeli, ReLU aktivasyon fonksiyonu ve %50 dropout (eğitim tamamlama) oranı ile yapılandırılmıştır. Model, son katmanda Softmax aktivasyonu kullanarak çok sınıflı sınıflandırma yapmış ve optimizasyon için Adamax algoritması kullanılmıştır. Eğitim sırasında öğrenme oranı 0.01 olarak belirlenmiş ve model 50 dönem boyunca eğitilmiştir. Elde edilen sonuçlara göre CNN modelinin %97.60 doğruluk, %97 geri çağırma ve %99.26 Eğri Altındaki Alan - Area Under the Curve (AUC) ile diğer yöntemlerden üstün olduğu gösterilmiştir.

Pallawi ve Singh tarafından yapılan çalışmada, Alzheimer hastalığının dört evresi sınıflandırılmıştır [19]. Veri seti, Kaggle platformundan alınmış demans (2240 görüntü), MCI (896 görüntü), orta düzey bilişsel bozukluk (64 görüntü) ve CN (3200 görüntü) olmak üzere toplam 6400 MR görüntüsünden oluşmuş ve veri artırımı yöntemleriyle dengelenmiştir. Sınıflandırma için EfficientNetB0 modeli, transfer öğrenimiyle ince ayar yapılarak kullanılmıştır. Model, 50 epoch boyunca Adam optimizasyon algoritmasıyla eğitilmiş ve doğruluk oranı %95,78 olarak ölçülmüştür. Performans değerlendirmesi, doğruluk, hassasiyet, duyarlılık, F1

skoru ve kayıp gibi metriklerle yapılmıştır. Çalışma, modelin diğer yöntemlere kıyasla üstün performans gösterdiğini ortaya koymuştur.

Fong vd. Alzheimer hastalığının teşhisi için MR görüntülerinin ön işleme aşamalarını atlayarak bir DL nesne algılama yaklaşımı geliştirmiştir [20]. Araştırma, ADNI ve OASIS veri tabanından alınan 1000 MR görüntüsü (500 AD ve 500 CN) kullanılarak gerçekleştirilmiştir. Çalışmada Hızlı Bölgesel CNN - Faster Region CNN (Faster R-CNN), Tek Adımda Çoklu Kutu Dedektörü - Single Shot Multibox Detector (SSD) ve YOLOv3 gibi DL nesne algılama mimarileri değerlendirilmiştir. Bu yöntemler, MR görüntü ön işleme teknikleri olmaksızın, hipokampal bölgenin lokalizasyonu ve sınıflandırılması için kullanılmıştır. YOLOv3, sınıflandırmada %99.8 doğruluk oranıyla en iyi performansı göstermiştir. Çalışmada, Alzheimer teşhisinde ön işleme aşamalarını ortadan kaldırarak daha hızlı ve sade bir yaklaşım sunulurken yüksek doğruluk oranları elde edilmiştir.

Kancharla çalışmasında, Alzheimer hastalığının erken tespiti için MR görüntülerinden yararlanarak ML ve DL yöntemlerini karşılaştırmıştır [21]. Çalışmada OASIS veri seti kullanılarak 657 MR görüntüsü CN, MCI olarak iki sınıfa ayrılmıştır. Veri, %20 test ve %80 eğitim olarak bölünmüş, eğitim verisi ayrıca %10'luk bir doğrulama setine ayrılmıştır. Veri artırımı işlemiyle sınıf dengesizliği giderilmiş, ConvNextXLarge modeli ile özellik çıkarımı yapılmıştır. Çok Katmanlı Algılayıcı - Multilayer Perceptron (MLP), KNN, Aşırı Gradyan Artırma - eXtreme Gradient Boosting (XGB) ve RF modelleri performans açısından değerlendirilmiştir. MLP, test verisinde %95.3 doğruluk ve 1.0 hatırlama skoru ile en iyi performansı göstermiştir. Sonuçlar, ML modellerinin, Alzheimer teşhisinde geleneksel yöntemlerden daha hassas olabileceğini ortaya koymaktadır.

Mujahit vd., Alzheimer hastalığının farklı evrelerini sınıflandırmak amacıyla halka açık Kaggle Alzheimer MR veri setlerini kullanarak iki farklı veri yapısında (ikili ve çok sınıflı)

nıflı) kapsamlı bir derin öğrenme çalışması gerçekleştirmiştir [22]. Çok sınıflı veri setinde dört sınıf yer almakta olup: Hafif demans (896 görüntü), orta düzey demans (64 görüntü), demans olmayan (3200 görüntü) ve çok hafif demans (2240 görüntü); ikili sınıflı veri setinde ise Alzheimer hastası (965 görüntü) ve hafif bilişsel bozukluk (689 görüntü) olmak üzere iki sınıf bulunmaktadır. Görsellerin çözünürlükleri farklı olduğundan tüm görüntüler 224x224x3 boyutunda yeniden boyutlandırılmış ve veri setinde görülen ciddi sınıf dengesizliği, ADASYN yöntemiyle giderilmiştir. Görüntü ön işleme aşamasında doğrudan görsel kontrast ve boyut işlemleri uygulanmış, özellik çıkarımı ise tamamen derin öğrenme modelleri ile otomatik olarak gerçekleştirilmiştir. Çalışmada hem bireysel hem de topluluk tabanlı derin öğrenme mimarileri kullanılmıştır. Bireysel olarak test edilen modeller arasında CNN, DenseNet-121, EfficientNet-B2, VGG-16 ve Xception yer alırken; topluluk modeller ise bu yapıların farklı kombinasyonlarından (örneğin EfficientNet-B2 + VGG-16) oluşturulmuştur. Tüm modeller, transfer öğrenme tekniğiyle eğitilmiş; optimizasyon için Adam, kayıp fonksiyonu olarak ise categorical crossentropy seçilmiştir. En başarılı sonuçlar, VGG-16 ile EfficientNet-B2'nin birleşiminden oluşan topluluk model ile elde edilmiş; bu model çok sınıflı veri setinde %97.35 doğruluk ve %99.64 AUC, ikili sınıflı veri setinde ise %97.09 doğruluk ve %99.59 AUC sağlamıştır. K-katlı çapraz doğrulamada da bu model ortalama %96.3 doğruluk ile istikrarlı performans sergilemiş; diğer çalışmalarla karşılaştırıldığında en yüksek başarıyı göstererek Alzheimer hastalığının erken ve doğru teşhisi için etkili, hızlı ve yüksek doğruluklu bir yaklaşım sunduğu gösterilmiştir.

Pradhan vd, Alzheimer hastalığının erken teşhisini desteklemek amacıyla derin öğrenme temelli bir sistem geliştirmiş ve MR, Elektronik Sağlık Kayıtları (EHR) ve Tek Nükleotid Polimorfizmi (SNP) olmak üzere üç farklı veri seti üzerinde uygulamıştır [23]. MR görüntüleriyle yapılan çalışmalarda hastalık demans olmayan, çok hafif demans, hafif demans ve orta

dereceli demans olarak dört sınıfa ayrılmıştır. Görüntüler **CNN** mimarisi ile analiz edilmiş, modelde 14 evrişim katmanı, 5 max-pooling (maksimum havuzlama) ve 3 batch normalization (toplu normalleştirme) katmanı kullanılmıştır. Her bir veri türü (**MR**, **EHR**, **SNP**) için ayrı modeller eğitilmiş ve doğruluk, kesinlik, duyarlılık, F1 skoru gibi performans metrikleri karmaşıklık matrisi üzerinden hesaplanmıştır. En yüksek başarı, genetik verilerin yer aldığı **SNP** veri setinde %99.2 doğruluk oranı ile elde edilmiştir. Ayrıca, önerilen modelin başarısı, literatürde sıkça kullanılan önceden eğitilmiş **DenseNet**, **ResNet-50**, **VGG-Net** ve **EfficientNet** mimarileriyle karşılaştırılmıştır. Önerilen özel **CNN** yapısı, hem görüntüleme hem de genetik ve klinik verilerle yüksek doğrulukla çalışarak Alzheimer evrelerinin belirlenmesinde etkili olmuştur. Çalışma sonucunda geliştirilen sistemin, klinisyenlere erken tanı sürecinde yardımcı olabilecek güçlü bir karar destek sistemi potansiyeli taşıdığı sonucuna varılmıştır.

Venugopalan vd., Alzheimer hastalığının farklı evrelerini sınıflandırmak amacıyla halka açık **ADNI** veri setini kullanarak multimodal (çoklu veri türü) bir derin öğrenme yaklaşımı geliştirmiştir [24]. Çalışmada 2004'ü klinik test verisine (**EHR**), 503'ü **MR** görüntülerine, 808'i genetik veriye (**SNP**) sahip veri seti kullanılmıştır. Sınıflandırma işlemleri hem iki sınıflı (**CN** vs. **AD/MCI**) hem de üç sınıflı (**CN**, **MCI**, **AD**) olarak gerçekleştirilmiştir. Görüntü verileri ön işleme aşamasında standardize edilerek **MR** beyin görüntülerindeki 18 farklı anatomik bölgeden (ör. hipokampus, amigdala) 9108 vokselle çıkarılmıştır. Klinik veriler; bellek, denge ve nöropsikolojik testler, demografik bilgiler, ilaç kullanımı ve biyokimyasal ölçümlerden oluşmaktadır. Genetik veriler ise 2012–2013 yıllarında tam genom dizileme (Whole Genome Sequencing) yoluyla elde edilen **SNP** varyasyonlarıdır. Klinik ve **SNP** verileri için yığılı gürültülü otomatik kodlayıcılar, **MR** görüntüleri içinse 3 boyutlu evrişsel sinir ağları (3D-**CNN**) kullanılarak ara özellik çıkarımı yapılmıştır. Daha sonra bu ara özellikler birleş-

tirilerek, **RF**, **SVM**, **DT** ve **KNN** algoritmaları ile sınıflandırma yapılmıştır. Özellik düzeyi, ara özellik düzeyi ve karar düzeyi olmak üzere üç ayrı veri entegrasyon yöntemi test edilmiş, en iyi sonuçlar ara özellik düzeyi + **RF** sınıflandırıcı ile elde edilmiştir. Çalışma kapsamında geliştirilen modellerin performansı doğruluk, hassasiyet, geri çağırma ve F1 skoru gibi metriklerle değerlendirilmiş ve **MR** verisinde **DL** modeliyle %86 doğruluk elde edilmiştir. Ayrıca model yorumlanabilirliğini artırmak adına bozulma tabanlı analiz uygulanarak, sınıflandırmada en etkili özelliklerin hipokampus hacmi, amigdala yapısı ve Rey İşitsel Sözlü Öğrenme Testi - Rey Auditory Verbal Learning Test (**RAVLT**) gibi biyobelirteçler olduğu gösterilmiştir.

Zhao vd., Alzheimer hastalığına yönelik yapay zekâ temelli araştırmaları derinlemesine inceledikleri çalışmalarında, görüntüleme, genetik, dilsel ve klinik veriler gibi farklı modalitelerde gerçekleştirilen literatürdeki yaklaşık 100 çalışmayı analiz ederek sınıflandırmıştır [25]. Çalışmada, yaygın şekilde kullanılan **ADNI**, Ulusal Alzheimer Koordinasyon Merkezi - National Alzheimer's Coordination Center (**NACC**), **OASIS**, UK Biobank ve DementiaBank gibi açık erişimli veri setlerinden elde edilen veriler doğrultusunda gerçekleştirilen tanı, prognoz, etiyoloji keşfi ve tedaviye yönelik yapay zekâ uygulamaları değerlendirilmiştir. Sınıflandırma çalışmaları, hem ikili hem de dördü sınıflar arasında gerçekleştirilmiş olup; bazı çalışmalarda sadece **MR** verileri, bazılarında ise Pozitron Emisyon Tomografisi - Positron Emission Tomography (**PET**), genetik, klinik testler ve dil verileri ile çoklu veri türleri birleştirilerek analiz yapılmıştır. Görüntü işleme sürecinde beyin segmentasyonu, kortikal kalınlık, gri madde yoğunluğu ve tekstürel özellik çıkarımı gibi teknikler kullanılmış; sınıflandırma için ise **SVM**, **KNN**, **RF**, Naive Bayes (**NB**), **DT** gibi klasik yöntemlerle birlikte **CNN**, Derin Sinir Ağı - Deep Neural Network (**DNN**), Uzun Kısa Süreli Bellek - Long Short Term Memory (**LSTM**), Kapılı Tekrarlayan Birim - Gated Recurrent Unit (**GRU**), Graf Sinir Ağları - Graph Neural Network (**GNN**), dikkat mekanizmaları, few-shot learning (birkaç adımda

öğrenme) ve grafik tabanlı derin öğrenme modelleri de değerlendirilmiştir. İncelenen çalışmalarda AD/CN ayrımında %97.91'e varan, MCI'dan Alzheimer'a dönüşüm tahmininde ise %94.64'e varan doğruluk oranlarına ulaşıldığı rapor edilmiştir. Makalede ayrıca farmakolojik ve farmakolojik olmayan tedavi yaklaşımlarının yapay zekâ ile desteklenmesine dair güncel literatür örneklerine yer verilmiş, tüm bu bulgular doğrultusunda açıklanabilir yapay zekâ, veri standardizasyonu ve multimodal sistem entegrasyonu gibi konuların gelecekteki Alzheimer araştırmaları için kritik öneme sahip olduğu vurgulanmıştır.

Çizelge 1'de MR görüntüleri kullanılarak yapılan literatür araştırmaları listelenmiştir.

Çizelge 1: MR Literatür Özeti

Araştırmacılar	Veri Seti	Kullanılan Yöntemler	Performans Metrikleri	Başarım
Dasu vd. [1]	8960 hafif, 6464 orta, 9600 CN, 8960 çok hafif	CLAHE, Otsu, GLMC, SVM, KNN, DT	Karışıklık Matrisi, Duyarlılık, Özgüllük, Doğruluk	%95
Sertkaya vd.[2]	507 MCI, 489 CN, 459 AD	Gradyan filtresi, DenseNet201, CNN	Doğruluk	%98.63
Das vd.[3]	2240 çok hafif, 896 MCI, 64 orta, 3200 CN	ADASYN, DTL (VGG19, ResNet50, Xception, InceptionV3)	MCC, Dengeli Doğruluk Skoru	-
Patil vd.[4]	50 CN, 50 hafif, 50 orta, 50 AD	TensorFlow, ReLU, CNN, MobileNetV2	Özgüllük	%96.13
Mahmood vd.[5]	230 denek, toplam 457 görüntü	PCA, Çok sınıflı sinir ağı	Doğruluk	%89.92
Salunkhe vd.[6]	119 AD, 115 CN	GLMC, RF, DT, SVM	Doğruluk	%90.2
Alghamedy vd[7]	416 örnek	CLAHE, k-means, PCA, SVM-RBF, ANN, ID3	Doğruluk	%99
Kumar vd.[8]	50.000 görüntü	HOG, ML (SVM, RF, LR, DT), DL (CNN), Transfer Öğrenme	Doğruluk, Kesinlik, Geri Çağırma, F1 Skoru	%91 (Transfer)
Prasetyo [9]	1124 AD, 2590 MCI, 1440 CN	Xception, InceptionV3, VGG16, VGG19, MobileNet	Doğruluk	%100 (VGG19)
Uysal vd. [10]	159 AD, 217 MCI, 109 CN	LR, KNN, SVM, DT, RF, GNB	Özgüllük	%95 (GNB)
Veena vd.[11]	72 CN, 64 AD, 14 demansa ilerleyen	LR, SVM, DT, RF, AdaBoost	Doğruluk	%84

Araştırmacılar	Veri Seti	Kullanılan Yöntemler	Performans Metrikleri	Başarımlar
Demir[12]	6400 görüntü: 4 sınıf	MobileNetV2, VGG16, ReliefF, DT, LDA, SVM, KNN	Duyarlılık	%94.9
Oishi vd.[13]	10 AD, 10 CN	CPC, Gauss SVM	Duyarlılık	%94.9
Adhora vd.[14]	179 CN, 12 çok hafif, 620 hafif, 448 orta	SMOTE, CNN, InceptionV3, ResNet50	Duyarlılık	%95
Bharath M. vd.[15]	3200 CN, 2240 çok hafif, 896 hafif, 64 orta	LDA, SVM, VGG16, EfficientNetB0	Doğruluk	%94.9
R. Das vd.[16]	100 eğitim, 35 test AD + CN	3D-UNet	Doğruluk, F1-Skor	Segmentasyon %93, %91 (Kişi), %88 (Hemisfer)
Jayanthi vd.[17]	2240 çok hafif, 896 MCI, 64 orta, 3200 CN	VGG-16, Adamax, Çapraz Entropi	Doğruluk, Hassasiyet, Geri Çağırma, F1-skoru	%99.4 (Hassasiyet)
Mamun vd.[18]	6219 görüntü, 4 sınıf	CNN, VGG-16, Resnet-101, DenseNet121, ReLu, Adamax	Doğruluk, ROC, Geri Çağırma	%99.26 (AUC)
Pallawi ve Singh [19]	3200 CN, 2240 çok hafif, 896 hafif, 64 orta	EfficientNetB0, Adam	Doğruluk, Hassasiyet, Duyarlılık, F1-Skoru, Kayıp	%95.78
Fong vd. [20]	500 AD, 500 CN	Faster R-CNN, SSD, YOLOv3	-	%99.8
Kancharla [21]	657 görüntü	ConvNextXLarge, MLP, KNN, XGBoost, RF	Doğruluk, hatırlama skoru	%95.3
Mujahit vd. [22]	Çok sınıflı: 3200 CN, 2240 çok hafif, 896 hafif, 64 orta İkili: 965 AD, 689 MCI	ADASYN, CNN, DenseNet-121, EfficientNet-B2, VGG-16, Xception, Topluluk modeller, Transfer öğrenme, ADAM	Doğruluk, AUC, K-katlı çapraz doğrulama	Çok Sınıflı: %99.64 AUC
Pradhan vd. [23]	MRI (4 sınıflı), EHR, SNP	CNN, DenseNet, ResNet-50, VGG, EfficientNet	Doğruluk, Kesinlik, Duyarlılık, F1 Skoru, Karşıklık Matrisi	SNP: %99.2 doğruluk
Venugopalan vd. [24]	ADNI: 503 MR, 2004 EHR, 808 SNP	3D-CNN (MR), Stacked Denoising Autoencoder (EHR, SNP), RF, SVM, DT, KNN	Doğruluk, Hassasiyet, Geri Çağırma, F1 Skoru	MR verisinde %86 doğruluk
Zhao vd. [25]	ADNI, NACC, OASIS, UK Biobank, DementiaBank (MR, PET, Genetik, Klinik, Dil verileri)	Klasik ML (SVM, KNN, RF, NB, DT), Derin Öğrenme (CNN, DNN, LSTM, GRU, GNN), Dikkat mekanizmaları, Few-shot learning ve Grafik tabanlı yöntemler	Doğruluk, Açıklanabilirlik	Derleme Çalışması (100'e yakın çalışma incelenmiş)
Fahmi Khalifa vd. [26]	3200 CN, 2240 çok hafif, 896 hafif, 64 orta	CNN, Adam	Doğruluk , Duyarlılık, Özgüllük, ROC-AUC	%99.68
Emtiaz Hussain vd. [27]	416 örnek	12 katmanlı CNN, InceptionV3, Xception, MobileNetV2 ve VGG19	Doğruluk, Kesinlik, Duyarlılık, F1 Skoru, ROC	%97.75
Duaa AlSaeed vd. [28]	ADNI:741 denek (427 AD, 314 NC), MIRIAD: 708 tarama (46 AD, 23 NC)	ResNet50, SVM, SGD, RF,	Doğruluk, Duyarlılık, Özgüllük, F1 Skoru	ADNI: %99
Velid El Şehrasi [29]	5.377 görüntü	DenseNet-19, ResNet-50	Doğruluk, Eğri Altındaki Alan ve Kayıp	ADNI: %97.77
Ghazal vd. [29]	1017 Hafif, 1024 Orta, 2560 CN, 1792 Çok hafif	ADDTLA (Transfer Öğrenme), Değiştirilmiş AlexNet, SGDM, Çapraz Entropi	Doğruluk, Duyarlılık, Özgüllük, Kesinlik, F1 Skoru, FPR, FNR	ADNI: %99
Anacur vd. [30]	85 CN ve 89 AD	MLP, LR, SVM	Doğruluk, Duyarlılık, Özgüllük ve F1 Skoru	%84.43

BÖLÜM: İİ

MATERYAL

MATERYAL

Bu bölümde, çalışmada kullanılan materyaller ele alınmıştır. Bölüm 3.1’de kullanılan dil olarak Python, kullanılan ortam olarak Google Colaboratory ve bölüm 3.2’te de kullanılan veri seti açıklanmıştır.

3.1 *Kullanılan Programlama Dili ve Ortam*

Python; nesne yönelimli, yorumlamalı, modüler, yüksek seviyeli ve açık kaynaklı bir programlama dili olarak nitelendirilmektedir. Derleyiciye veya makine koduna dönüştürülmeden doğrudan çalıştırılabilmektedir. Popüler kütüphaneler arasında NumPy, Pandas, Matplotlib ve TensorFlow gibi araçlar bulunmaktadır. Yapısı bakımından doğal dile benzemektedir ve bu yapı yazılan kodun okunabilirliğini arttırmaktadır. Dinamik yapı olduğu için değişkenlerin türlerini belirtme zorunluluğu bulunmamaktadır. Yorumlanabilir olduğundan hata ayıklama işlemleri oldukça kolay olmaktadır. Kod çalıştırılmadan önce hatalar tespit edildiğinden geliştiricilerin daha hızlı geri bildirim almasını sağlamaktadır [31].

Google Colaboratory, kullanıcıların Python tabanlı kodları tarayıcı üzerinden çalıştırmasına olanak tanıyan, bulut tabanlı bir platformdur. Özellikle makine öğrenmesi ve derin öğrenme projelerinde GPU ve TPU desteği sayesinde hesaplama gücü sunar [32].


Bu çalışmada Colab platformunun Pro sürümü tercih edilmiştir. Bunun nedeni, Pro sürümünün sağladığı daha yüksek GPU kapasitesi ile modelin eğitim sürecini hızlandırması ve bekleme sürelerini önemli ölçüde azaltmasıdır. Bu sayede, büyük veri kümeleriyle yapılan eğitim süreçleri daha verimli ve zaman açısından tasarruflu hale getirilmiştir.

3.2 Kullanılan Veri Kümesi

Bu çalışmada kullanılan veri seti, halka açık bir platform olan Kaggle'dan alınmıştır [33]. Toplamda 6400 orijinal MR görüntüsünden oluşan veriler, dört sınıfa ayrılmıştır. Bu sınıflar hafif demans, orta derecede demans, demans olmayan ve çok hafif demans şeklindedir. Çizelge 2'de bu verilerin sınıflara göre dağılımı ve Şekil 1'de örnek MR görüntüleri bulunmaktadır.

Çizelge 2: Veri Seti Veri Dağılımı

	Hafif Demans	Orta Derece Demans	Demans Olmayan	Çok Hafif Demans
Orijinal Veriler	896	64	3200	2240



Şekil 1: Örnek MR Görüntüleri

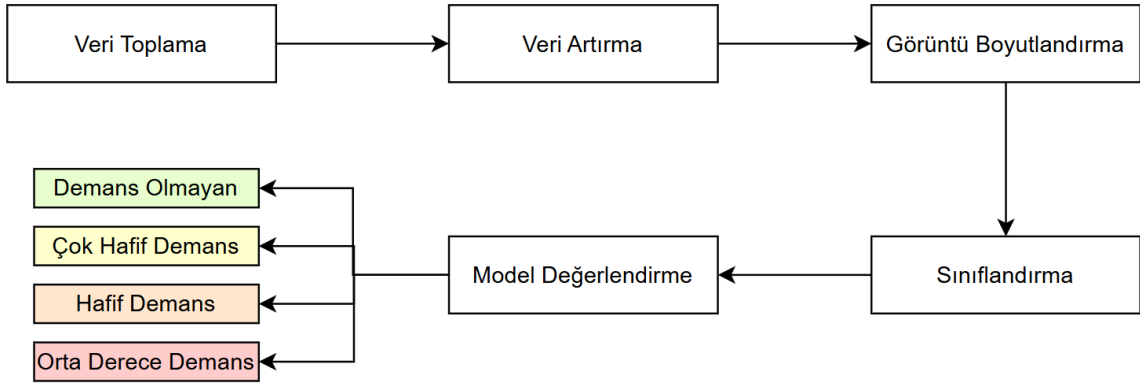
Veri seti içerisinde bu sınıflara ait orijinal verilerin yanı sıra mevcut veri kümesinden artırılarak oluşturulmuş iki klasör bulunmaktadır. Çalışmada veri setinin artırılmamış orijinal veri seti kısmı kullanılmıştır. Veri artırma yapıldığında orijinal verilerin sadece eğitim verileri yüzde elli oranında artırılmış olup test kısmında değişiklik yapılmamıştır. Bölüm 4.1’de anlatılan ön işleme adımları veri setine uygulandıktan sonra toplam yaklaşık 9 bin MR görüntüsü elde edilmiştir.

BÖLÜM: İİİ

YÖNTEM

YÖNTEM

Bu çalışmanın ön işleme aşamasında orijinal verilere veri artırma işlemi yapılmıştır. Ardından veri setindeki görüntüler boyutlandırılmıştır. Ön işleme tamamlanan veriler [ResNet-50](#), [VGG-16](#), [VGG-19](#), [DenseNet-121](#), [MobileNet-V2](#), [EfficientNet-B0](#) ve [CNN](#) algoritması ile sınıflandırılıp model performansı çeşitli metriklerle değerlendirilmiştir. Bölüm [4.1](#), [4.2](#) ve [4.3](#)'te bu adımlar detaylıca açıklanmış olup Şekil 2'de de çalışmanın metodolojisi bulunmaktadır.



Şekil 2: Metodoloji


4.1 Veri Ön İşleme

Veri ön işleme, veri artırma ve görüntü boyutlandırma olmak üzere 2 adımdan oluşmaktadır. Bölüm 4.1.1 ve 4.1.2’de bu adımlar sırasıyla anlatılmıştır.

4.1.1 Veri Artırma

Veri artırma, sınıf sayısını artırmadan mevcut görüntüleri çeşitli dönüşümlerle zenginleştirerek derin öğrenme modellerinin genelleme yeteneğini geliştirmeyi amaçlayan bir yöntemdir. Yaygın olarak kullanılan veri artırma teknikleri arasında döndürme, yansıma, çevirme, parlaklık ve kontrast ayarlamaları ile ölçekleme yer almaktadır. Bu tür işlemler, modelin farklı varyasyonlarla eğitilmesini sağlayarak overfitting riskini azaltır ve sınıflar arası veri dengesine katkıda bulunur.

Bu çalışmada veri artırma süreci, Python programlama dili kullanılarak TensorFlow Keras kütüphanesi aracılığıyla gerçekleştirilmiştir. Görüntü verileri %70 ve %80 eğitim, %30 ve %20 test olmak üzere iki ayrı alt kümeye ayrılmıştır. Yalnızca eğitim verileri üzerinde fiziksel veri artırma uygulanmıştır. Bu kapsamda eğitim verileri çeşitli dönüşümlerle çoğaltılarak her sınıf için eğitim verileri %50 oranında artırılmış ve veri kümesine yeni görüntü dosyaları olarak eklenmiştir. Böylece modelin daha çeşitli örneklerle eğitilmesi sağlanmıştır. Şekil 3’te rastgele bir görüntüye uygulanan işlemler sonucu oluşan artırılmış görüntülere örnek verilmiştir. Çizelge 3’te %80 eğitim, %20 test olarak bölünmüş verilerin sınıflara göre dağılımı bulunurken Çizelge 4’te de %70 eğitim, %30 test olarak bölünmüş verilerin sınıflara göre dağılımı verilmiştir.



Şekil 3: Artırılmış Veri Setinden Örnek Görüntüler

Çizelge 3: 80-20 Veri Setinin Sınıflara Göre Dağılımı

	Eğitim (%80)					Test (%20)					Toplam
	Demans	Orta Derece	Hafif	Çok Hafif	Toplam	Demans	Orta Derece	Hafif	Çok Hafif	Toplam	
	Olmayan	Demans	Demans	Demans		Olmayan	Demans	Demans	Demans		
Orijinal Veri Seti	2560	51	716	1792	5119	640	13	180	448	1281	6400
%50 Artırılmış Veri Seti	3840	76	1074	2688	7678	640	13	180	448	1281	8959

Çizelge 4: 70-30 Veri Setinin Sınıflara Göre Dağılımı

	Eğitim (%70)					Test (%30)					Toplam
	Demans	Orta Derece	Hafif	Çok Hafif	Toplam	Demans	Orta Derece	Hafif	Çok Hafif	Toplam	
	Olmayan	Demans	Demans	Demans		Olmayan	Demans	Demans	Demans		
Orijinal Veri Seti	2240	44	627	1568	4479	960	20	269	672	1921	6400
%50 Artırılmış Veri Seti	3360	66	940	2352	6718	960	20	269	672	1921	8639


4.1.2 Görüntü Boyutlandırma

DL modelleri sabit boyutta girdiler gerektirir. Tüm görüntüleri aynı boyuta getirmek, modelin işlemlerini kolaylaştırmaktadır. Bu yüzden veri setindeki görüntülerin **CNN** modellerinin

sabit giriş boyutlarına 224×224 getirilmesi gerekmektedir. Bunun için Python dilinin Python Imaging Library (PIL) kütüphanesi kullanılarak görüntüler 224×224 boyutuna getirilmiştir.

4.2 Sınıflandırma

Beyin görüntülerini analiz etmek amacıyla bu çalışmada hem Bölüm 4.2.1’de anlatılan sıfırdan eğitilen bir CNN modeli hem de Bölüm 4.2.2’de anlatılan transfer öğrenme yaklaşımları kullanılmıştır. Transfer öğrenme kapsamında ResNet-50, VGG-16, VGG-19, MobileNet-V2, EfficientNet-B0 ve DenseNet-121 gibi önceden eğitilmiş CNN mimarileri kullanarak model performansları karşılaştırılmıştır. Modellerin adil bir şekilde karşılaştırılması için Çizelge 5’te verilen parameteler ve Şekil 4’te verilen öğrenme oranları (learning rate) mümkün olduğunca korunmuştur. Örneğin, Stokastik Gradyan İnişi - Stochastic Gradient Descent (SGD) optimizasyon fonksiyonu için 0.01 tercih edilirken Adam optimizasyon fonksiyonu için 0.001 değerinde bir öğrenme oranı tercih edilmiştir. Ancak, modelin eğitim sürecinin iyileştirilmesi amacıyla mimariler üzerinde dropout oranı, öğrenme oranı ve mini batch boyutu gibi bazı parametrelerde değişiklikler yapılmıştır.



Şekil 4: Optimizasyonların Öğrenme Oranları

Çizelge 5: Model Parametreleri

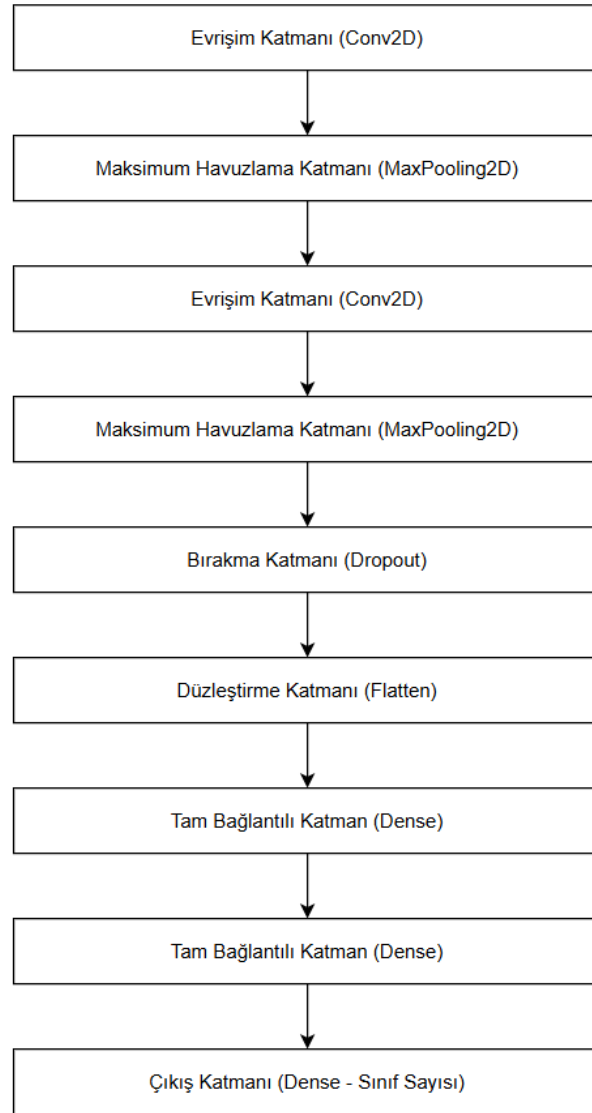
Parametre	Değer
Optimizasyon Yöntemi	Adam, SGD, Nadam, RMSprop, Adadelta, Adagrad
Kayıp Fonksiyonu	Categorical Crossentropy
Başarı Ölçütü (Metrik)	Doğruluk, Duyarlılık, Kesinlik, F1-Skoru
Girdi Boyutu	(224, 224, 3)
Epoch Sayısı	30
Mini Batch Boyutu	32
Dropout Oranı	0.5
Aktivasyon (Ara Katman)	ReLU
Aktivasyon (Çıkış Katmanı)	Softmax

4.2.1 CNN

CNN, özellikle görsel verileri işlemek ve analiz etmek için kullanılan bir derin öğrenme modelidir. Görüntü işleme, bilgisayarla görme, video analizi ve doğal dil işleme gibi alanlarda yaygın olarak kullanılmaktadır. Görsellerdeki örüntüleri tanıma ve sınıflandırma gibi görevlerde oldukça etkilidir ve geleneksel yapay sinir ağlarının bir uzantısıdır.

Bu çalışmada, **CNN** mimarilerinin performanslarını değerlendirebilmek adına farklı katman ve nöron kombinasyonları denenmiştir. Özellikle konvolüsyonel katman sayısı ile bu katmanlardaki filtre boyutlarının model başarımı üzerindeki etkisi araştırılmıştır. Bu kapsamda; 32x32, 64x64, 32x32x32x32, 64x64x64x64 ve 32x32x64x64 şeklinde 5 farklı filtre yapılandırmaları kullanılmıştır. Şekil 5'te **CNN** için model mimarisi verilmiştir. Her bir CNN modeli, giriş görüntüsünden anlamlı öznitelikler çıkarmak amacıyla birden fazla evrişim ve maksimum havuzlama katmanları ile yapılandırılmıştır. Bu katmanlar sayesinde hem uzamsal boyutlar azaltılmış hem de modelin öğrenmesi için önemli özellikler vurgulanmıştır.

Aşırı öğrenmeyi önlemek ve modelin genelleme kabiliyetini artırmak amacıyla, bu katmanların ardından birden fazla bırakma katmanı entegre edilmiştir. Özellik haritaları daha sonra düzleştirme katmanı ile tek boyutlu hale getirilmiş ve sınıflandırma işlemi, ardışık olarak yerleştirilen tam bağlantılı katmanlarla gerçekleştirilmiştir. Son katmanda ise sınıf sayısı kadar nöron içeren bir çıkış katmanı bulunmaktadır. Filtre sayısı 4 olduğunda (örn. $32 \times 32 \times 32 \times 32$) bu CNN mimarisine, farklı olarak düzleştirme katmanından önce ikişer tane daha evrişim, havuzlama ve dropout katman blokları eklenmiştir ve böylece mimari daha derin öğrenme kapasitesine sahip hale getirilmiştir.



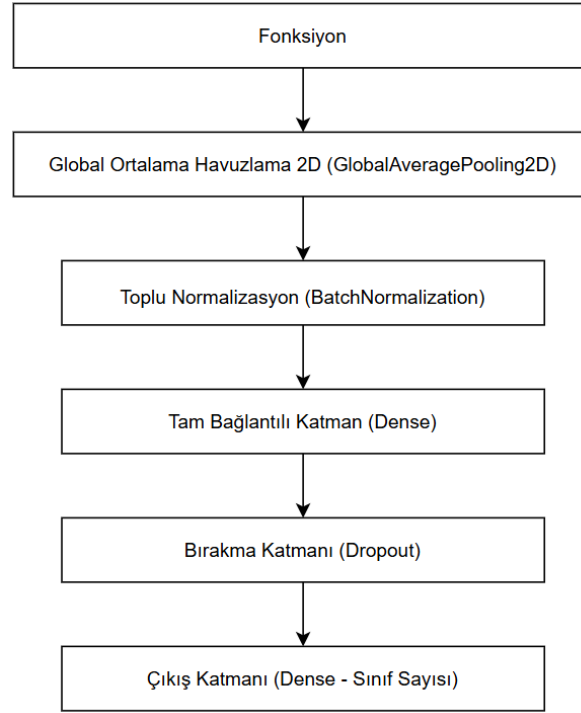
Şekil 5: CNN Model Mimarisi

4.2.2 Transfer Öğrenme Mimarileri

Transfer öğrenme, büyük veri üzerinde eğitilmiş modellerin bilgi birikimini daha küçük ve özel görevlere aktararak öğrenmeyi hızlandıran ve daha az veriyle daha iyi sonuçlar elde etmeyi hedefleyen bir yaklaşımdır. Alzheimer hastalığı sınıflandırması gibi sınırlı veri setine sahip olunan durumlarda büyük avantaj sunar.

Bu çalışmada, yüksek performanslı, önceden eğitilmiş CNN mimarileri (ResNet-50, VGG-16, VGG-19, MobileNetV2, EfficientNet-B0, DenseNet-121) transfer öğrenme amacıyla kullanılmıştır. Bu modellerin genel görsel özellikleri öğrenmiş olması, hedef veri setindeki beyin görüntülerinin etkili bir şekilde sınıflandırılmasına olanak tanımaktadır. Model performansını optimize etmek için farklı ince ayar stratejileri ve hiperparametre optimizasyonları uygulanmıştır. Şekil 6’da transfer öğrenme yöntemleri için model mimarisi verilmiştir. Her bir transfer öğrenme modeline, özellik haritalarını özetlemek için global ortalama havuzlama, eğitimi stabilize etmek için toplu normalizasyon, sınıflandırma için tam bağlantılı katmanlar ve aşırı öğrenmeyi önlemek için bırakma katmanları sırasıyla eklenmiştir. ResNet-50 ve EfficientNet-B0 mimarisi, diğer modellere kıyasla ek bir tam bağlantılı katman ve bırakma katmanı daha içermektedir.

Bu çalışmada kullanılan transfer öğrenme mimarileri olan ResNet-50, VGG-16, VGG-19, DenseNet-121, MobileNet-V2 ve EfficientNet-B0, Bölüm 4.2.2.1, 4.2.2.2, 4.2.2.3, 4.2.2.4, 4.2.2.5 ve 4.2.2.6’da anlatılmıştır.



Şekil 6: Transfer Öğrenme Model Mimarisi

4.2.2.1 Resnet-50

ResNet-50, derin sinir ağlarının eğitimini kolaylaştıran artı bağlantılar kullanarak 50 katman derinliğe ulaşan güçlü bir **CNN** mimarisidir. Görüntü sınıflandırma, nesne algılama ve transfer öğrenme gibi birçok alanda yaygın olarak kullanılmaktadır.

4.2.2.2 VGG-16

VGG-16 modeli, 13 konvolüsyon ve 3 tam bağlantılı katman olmak üzere toplam 16 ağırlıklı katmandan oluşur. Daha az katman içermesi, eğitim süresini kısaltmakta ve hesaplama maliyetini düşürmektedir. Bu nedenle, daha sınırlı kaynaklara sahip sistemlerde hızlı ve etkili çözümler sunar. Modelin başarısı, basit yapısının yüksek doğrulukla birleşmesinden kaynaklanmaktadır.

4.2.2.3 VGG-19

VGG-19, 16 konvolüsyon ve 3 tam bağlantılı katmanla toplamda 19 katmandan oluşur. Katman sayısındaki bu artış, modelin daha karmaşık özellikleri öğrenmesine olanak sağlasa da; aynı zamanda daha fazla parametre, daha uzun eğitim süresi ve daha yüksek donanım gereksinimi anlamına gelir. Pratik uygulamalarda, **VGG-19**'un sunduğu ek performans artışı her zaman bu maliyeti karşılamayabilir; bu nedenle çoğu senaryoda **VGG-16** daha dengeli bir tercih olarak öne çıkar.

4.2.2.4 DenseNet-121

DenseNet-121, özellikle sınırlı veri ile çalışılan durumlarda güçlü bir genelleme yeteneği sunar. Aynı doğruluk seviyesini, daha az parametre ile elde edebilmesi sayesinde, derin fakat verimli bir yapı sunar. Görüntü sınıflandırma, nesne tanıma gibi görevlerde yaygın olarak kullanılmaktadır.

4.2.2.5 MobileNet-V2

MobileNet-V2, derinlik ayrıştırırmalı evrişim ve tersine artık bağlantılar kullanarak hem model boyutunu küçültür hem de doğruluğu korur. Bu yapı, düşük hesaplama maliyetiyle verimli ve hızlı performans sunar.

4.2.2.6 EfficientNetB0

EfficientNet-B0, yüksek doğruluk ve düşük hesaplama maliyeti arasında denge sağlayan verimli bir derin öğrenme modelidir. Ölçeklendirme işlemini derinlik, genişlik ve çözünürlük boyutlarında dengeli bir şekilde yaparak optimize performans sunar. Mobil ve sınırlı kaynaklı sistemler için uygundur.

4.3 Performans Metrikleri ile Değerlendirme

Bu çalışmada model; doğruluk, duyarlılık, kesinlik ve F1-Skoru metrikleri ile karmaşıklık matrisi üzerinden değerlendirilmiştir. Bu matris, sınıflandırma problemlerinde modelin performansını değerlendirmek için kullanılan temel araçlardan biridir. Modelin tahminleri ile gerçek değerleri karşılaştırarak ne kadar doğru ve yanlış tahminde bulunduğunu gösteren bir tablodur. Şekil 7’de genel bir karmaşıklık matrisi verilmiştir.

		Gerçek Değerler	
		Pozitif (1)	Negatif (0)
Tahmin Değerleri	Pozitif (1)	True Positive	False Positive
	Negatif (0)	False Negative	True Negative

Şekil 7: Karmaşıklık Matrisi

Doğruluk metriği, bir sınıflandırma modelinin toplam tahminlerinin içinde doğru tahmin oranını ifade eder ve modelin genel performansını değerlendirmeye yardımcı olmaktadır. Veri dengeli olduğunda modelin performansı hakkında daha iyi sonuçlar vermektedir. Denklem 1’de doğruluk metriği formülize edilmiştir.

$$\text{Doğruluk} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Duyarlılık metriği, bir sınıflandırma modelinin gerçek pozitiflerinin ne kadar doğru şekilde hesaplandığını ölçmektedir. Yanlış negatif tahminler ciddi sonuçlara neden olabilmektedir.

Bu nedenle, modelin duyarlılığını değerlendirmek gerçek pozitiflerin gözden kaçma riskini en aza indirmektedir. Denklem 2’de duyarlılık metriği formülize edilmiştir.

$$\text{Duyarlılık} = \frac{TP}{TP + FN} \quad (2)$$

Kesinlik metriği, bir sınıflandırma modelinin pozitif olarak tahmin ettiği ögelerden kaç tanesinin gerçekten pozitif olduğunu ölçmektedir. Denklem 3’te kesinlik metriği formülize edilmiştir.

$$\text{Kesinlik} = \frac{TP}{TP + FP} \quad (3)$$

F1-Skoru metriği, hem yanlış pozitiflerin hem de yanlış negatiflerin etkisini dengeleyerek modelin genel performansını daha doğru bir şekilde değerlendirmektedir. Özellikle dengesiz sınıflandırma problemleri veya farklı maliyetlerin olduğu durumlarda uygun bir değerlendirme aracıdır. Denklem 4’te F1-skoru metriği formülize edilmiştir.

$$F1 = 2 \cdot \frac{\text{Kesinlik} \cdot \text{Duyarlılık}}{\text{Kesinlik} + \text{Duyarlılık}} \quad (4)$$

BÖLÜM: İV

SONUÇ

SONUÇ

Çalışmada Alzheimer hastalığının sınıflandırılması için 7 farklı **DL** modeli, 6 farklı optimizasyon fonksiyonu ile hem 80-20 eğitim-test oranında hem de 70-30 eğitim-test oranında bölünmüş; orijinal ve artırılmış veri seti olmak üzere 2 veri seti üzerinde denenmiştir. Bölüm 5.1 ve 5.2’de bu modellere ait deneysel sonuçlar verilmiştir. Bölüm 5.3’te çalışma, önceki çalışmalarla kıyaslanmıştır. Bölüm 5.4’te de çalışmaya ait sonuçlar yorumlanmıştır.

5.1 *Transfer Öğrenme Modellerinde Optimizasyonların Sınıflandırma Başarımına Etkisi*

Bu bölümde **Adam**, Nesterov Hızlandırılmış Adam - Nesterov Accelerated Adam (**Nadam**), **SGD**, Ortalama Karekök Yayılımı - Root Mean Square Propagation (**RMSprop**), Adadelata ve Uyarlanabilir Gradyan Algoritması - Adaptive Gradient Algorithm (**Adagrad**) optimizasyonlarının **ResNet-50**, **VGG-16**, **VGG-19**, **DenseNet-121**, **MobileNet-V2** ve **EfficientNet-B0** transfer öğrenme modelleri üzerindeki başarımları doğruluk, duyarlılık, kesinlik ve F1 Skoru metrikleri kullanılarak incelenmiştir. Transfer öğrenme modelleri farklı optimizasyonlar ile hem orijinal hem de artırılmış ve hem 80-20 oranında hem de 70-30 oranında bölünen veri seti üzerinde ayrı ayrı değerlendirilmiştir.

Model eğitimleri sonuçlarına göre 70-30 oranında bölünen orijinal veri seti ile yapılan deneyde en yüksek sonuç tüm metriklerde %97.66 başarımla oranı ile **ResNet-50** modelinde **Nadam** optimizasyonu olmuştur. Çizelge 6 ve Çizelge 7’ye bakılarak diğer transfer öğrenme modelleri ve optimizasyonlar incelendiğinde **Nadam** optimizasyonunun diğer optimizasyonlara göre daha iyi sonuçlar verdiği ve **EfficientNet-B0** modelinin **ResNet-50** modeline yakın sonuçlar verdiği görülmektedir.

Çizelge 6: 70-30 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (1)

	Adam				Nadam				SGD			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9760	0.9760	0.9764	0.9761	0.9766	0.9766	0.9766	0.9766	0.9646	0.9646	0.9648	0.9646
VGG16	0.9256	0.9256	0.9256	0.9253	0.9391	0.9391	0.9396	0.9388	0.9204	0.9204	0.9221	0.9205
VGG19	0.9266	0.9266	0.9275	0.9267	0.9391	0.9391	0.9396	0.9390	0.9276	0.9276	0.9280	0.9274
DenseNet121	0.9305	0.9305	0.9319	0.9307	0.9360	0.9360	0.9362	0.9360	0.9126	0.9126	0.9128	0.9123
MobileNetV2	0.8771	0.8771	0.8763	0.8764	0.8991	0.8990	0.9010	0.8991	0.8771	0.8771	0.8764	0.8764
EfficientNetB0	0.9732	0.9729	0.9729	0.9729	0.9714	0.9714	0.9714	0.9713	0.7010	0.7010	0.6951	0.6965

Çizelge 7: 70-30 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (2)

	RMSprop				Adadelta				Adagrad			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9609	0.9609	0.9622	0.9611	0.9766	0.9766	0.9766	0.9765	0.9641	0.9641	0.9642	0.9641
VGG16	0.9261	0.9261	0.9261	0.9260	0.9240	0.9240	0.9243	0.9239	0.8287	0.8287	0.8302	0.8264
VGG19	0.9313	0.9313	0.9315	0.9311	0.9235	0.9235	0.9237	0.9229	0.8157	0.8157	0.8215	0.8123
DenseNet121	0.9110	0.9110	0.9113	0.9108	0.9120	0.9120	0.9134	0.9121	0.8235	0.8235	0.8248	0.8219
MobileNetV2	0.8818	0.8818	0.8815	0.8811	0.8751	0.8751	0.8746	0.8743	0.8022	0.8022	0.8045	0.8000
EfficientNetB0	0.9755	0.9755	0.9756	0.9755	0.9812	0.9812	0.9814	0.9813	0.9725	0.9724	0.9724	0.9724

80-20 oranında bölünen orijinal veri seti ile yapılan model eğitimleri sonucunda en yüksek sonuç kesinlik metriğinde %99.15 başarımla oranı ile **EfficientNet-B0** modelinde Adadelta optimizasyonu olmuştur. Çizelge 8 ve Çizelge 9’a bakılarak diğer transfer öğrenme modelleri

ve optimizasyonlar incelendiğinde **Nadam** ve Adadelta optimizasyonlarının diğer optimizasyonlara göre daha iyi sonuçlar verdiği ve **ResNet-50** modelinin **EfficientNet-B0** modeline yakın sonuçlar verdiği görülmektedir.

Çizelge 8: 80-20 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (1)

	Adam				Nadam				SGD			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9836	0.9836	0.9837	0.9836	0.9852	0.9852	0.9852	0.9852	0.9844	0.9844	0.9845	0.9844
VGG16	0.9313	0.9313	0.9322	0.9311	0.9477	0.9477	0.9478	0.9476	0.9235	0.9235	0.9240	0.9234
VGG19	0.9360	0.9360	0.9284	0.9360	0.9539	0.9539	0.9540	0.9539	0.9336	0.9336	0.9338	0.9335
DenseNet121	0.9032	0.9032	0.9048	0.9032	0.9146	0.9146	0.9147	0.9146	0.8954	0.8954	0.8960	0.8950
MobileNetV2	0.8977	0.8977	0.8975	0.8974	0.8923	0.8923	0.8919	0.8920	0.9040	0.9040	0.9042	0.9040
EfficientNetB0	0.9820	0.9820	0.9820	0.9820	0.9773	0.9773	0.9776	0.9774	0.7172	0.7172	0.7080	0.7116

Çizelge 9: 80-20 Oranında Bölünmüş Orjinal Veri Setinde Optimizasyonların Transfer öğrenme Yöntemlerindeki Başarımı (2)

	RMSprop				Adadelta				Adagrad			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9820	0.9820	0.9823	0.9821	0.6789	0.6789	0.7260	0.6797	0.9812	0.9812	0.9812	0.9812
VGG16	0.9352	0.9352	0.9354	0.9351	0.9321	0.9321	0.9330	0.9318	0.8415	0.8415	0.8433	0.8405
VGG19	0.9321	0.9321	0.9320	0.9319	0.9313	0.9313	0.9338	0.9318	0.8283	0.8283	0.8309	0.8277
DenseNet121	0.9165	0.9165	0.9168	0.9161	0.9297	0.9297	0.9306	0.9296	0.8376	0.8376	0.8437	0.8377
MobileNetV2	0.9024	0.9024	0.9022	0.9021	0.8915	0.8915	0.8923	0.8914	0.8488	0.8493	0.8488	0.8482
EfficientNetB0	0.9823	0.9820	0.9820	0.9821	0.9914	0.9914	0.9915	0.9914	0.9727	0.9727	0.9728	0.9726

70-30 oranında bölünen ve artırılmış veri seti ile yapılan model eğitimleri sonucunda en yüksek sonuç kesinlik metriğinde %97.87 başarımla **ResNet-50** modelinde **RMSprop** optimizasyonu olmuştur. Çizelge 12 ve Çizelge 13'e bakılarak diğer transfer öğrenme modelleri ve optimizasyonlar incelendiğinde **Adam** ve **RMSprop** optimizasyonlarının diğer optimizasyonlara göre daha iyi sonuçlar verdiği ve **EfficientNet-B0** modelinin **ResNet-50** modeline yakın sonuçlar verdiği görülmektedir.

Çizelge 10: 70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların Transfer öğrenme

Yöntemlerindeki Başarımı (1)

	Adam				Nadam				SGD			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9724	0.9724	0.9724	0.9724	0.9724	0.9724	0.9725	0.9724	0.9458	0.9458	0.9459	0.9458
VGG16	0.9141	0.9141	0.9149	0.9141	0.9209	0.9209	0.9221	0.9211	0.9120	0.9120	0.9120	0.9119
VGG19	0.9276	0.9276	0.9290	0.9278	0.9224	0.9224	0.9241	0.9222	0.9125	0.9125	0.9129	0.9125
DenseNet121	0.8907	0.8907	0.8912	0.8906	0.8959	0.8959	0.8969	0.8959	0.8771	0.8771	0.8772	0.8763
MobileNetV2	0.9001	0.9001	0.9000	0.8994	0.9188	0.9188	0.9190	0.9188	0.9087	0.9087	0.9086	0.9076
EfficientNetB0	0.9557	0.9557	0.9562	0.9558	0.9406	0.9406	0.9406	0.9406	0.6932	0.6932	0.7061	0.6945

Çizelge 11: 70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların Transfer öğrenme

Yöntemlerindeki Başarımı (2)

	Rmsprop				Adadelata				Adagrad			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9786	0.9786	0.9787	0.9786	0.3844	0.3844	0.4745	0.3938	0.9672	0.9672	0.9677	0.9673
VGG16	0.9047	0.9047	0.9058	0.9043	0.9079	0.9079	0.9081	0.9078	0.8058	0.8058	0.8076	0.8034
VGG19	0.9240	0.9240	0.9247	0.9237	0.9136	0.9136	0.9146	0.9137	0.8152	0.8152	0.8215	0.8129
DenseNet121	0.8933	0.8933	0.8937	0.8930	0.8980	0.8980	0.8981	0.8977	0.8064	0.8064	0.8090	0.8051
MobileNetV2	0.9079	0.9079	0.9079	0.9073	0.8876	0.8876	0.8883	0.8873	0.8111	0.8111	0.8096	0.8079
EfficientNetB0	0.9625	0.9625	0.9625	0.9625	0.4062	0.4062	0.4034	0.3963	0.8229	0.8229	0.8455	0.8241

80–20 oranında bölünmüş ve artırılmış veri seti ile yapılan model eğitimleri sonucunda en yüksek sonuç tüm metriklerde %98.67 başarımla ile [ResNet-50](#) modelinde [RMSprop](#) optimizasyonu olmuştur. Çizelge 12 ve Çizelge 13’e bakılarak diğer transfer öğrenme modelleri ve optimizasyonlar incelendiğinde [Nadam](#) ve [RMSprop](#) optimizasyonlarının diğer optimizasyonlara göre daha iyi sonuçlar verdiği ve [EfficientNet-B0](#) modelinin [ResNet-50](#) modeline yakın sonuçlar verdiği görülmektedir.

Çizelge 12: 80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların Transfer öğrenme

Yöntemlerindeki Başarımı (1)

	Adam				Nadam				SGD			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9852	0.9852	0.9852	0.9851	0.9750	0.9750	0.9750	0.9750	0.9633	0.9633	0.9633	0.9633
VGG16	0.9375	0.9375	0.9377	0.9376	0.9321	0.9321	0.9321	0.9319	0.9305	0.9305	0.9312	0.9306
VGG19	0.9360	0.9360	0.9367	0.9361	0.9305	0.9305	0.9315	0.9306	0.9235	0.9235	0.9241	0.9235
DenseNet121	0.9141	0.9141	0.9141	0.9138	0.9196	0.9196	0.9204	0.9198	0.9063	0.9063	0.9096	0.9069
MobileNetV2	0.8938	0.8938	0.8938	0.8937	0.9180	0.9180	0.9179	0.9178	0.8977	0.8977	0.8981	0.8974
EfficientNetB0	0.9727	0.9727	0.9729	0.9727	0.9586	0.9586	0.9590	0.9586	0.7086	0.7086	0.7316	0.7120


Çizelge 13: 80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların Transfer öğrenme

Yöntemlerindeki Başarımı (2)


	Rmsprop				Adadelat				Adagrad			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
ResNet50	0.9867	0.9867	0.9867	0.9867	0.4430	0.4430	0.6525	0.4437	0.8953	0.8953	0.8980	0.8958
VGG16	0.9282	0.9282	0.9286	0.9283	0.9180	0.9180	0.9189	0.9178	0.8165	0.8165	0.8181	0.8154
VGG19	0.9290	0.9290	0.9297	0.9290	0.9321	0.9321	0.9327	0.9322	0.8212	0.8212	0.8242	0.8202
DenseNet121	0.9126	0.9126	0.9135	0.9124	0.9180	0.9180	0.9200	0.9177	0.8337	0.8337	0.8402	0.8340
MobileNetV2	0.9102	0.9102	0.9101	0.9100	0.8985	0.8985	0.8983	0.8979	0.8025	0.8025	0.8017	0.8002
EfficientNetB0	0.9797	0.9797	0.9799	0.9797	0.1867	0.1867	0.6316	0.1258	0.7969	0.7969	0.8398	0.8007

Bu deney sonucunda en yüksek sonuç kesinlik metriğinde %99.15 başarımlık oranı ile 80-20 oranında bölünmüş ve orijinal veri seti kullanılarak yapılan eğitim sürecinde Adadelat optimizasyonu ile **EfficientNet-B0** modeli olmuştur. Şekil 8’de bu sonuca ait doğruluk ve kayıp grafiği verilmiş olup, model yaklaşık 4. epoch’tan itibaren öğrenmeye başlamış ve doğruluk oranı düzenli şekilde artarken, kayıp değeri azalarak modelin öğrenme sürecinde istikrar kazandığı gösterilmiştir. Özellikle 10. epoch sonrasında eğrilerin daha dengeli bir seyir izlediği dikkat çekmektedir. Şekil 9’daki en iyi sonuca ait karmaşıklık matrisi ise modelin sınıflar arasında yüksek doğrulukla tahminler yaptığını ve yanlış sınıflandırmaların oldukça düşük seviyede gerçekleştiğini ortaya koymaktadır.

5.1 TRANSFER ÖĞRENME MODELLERİNDE OPTİMİZASYONLARIN SINIFLANDIRMA BAŞARIMINA ETKİLERİ



Şekil 8: Efficient-B0 Adadelta Optimizasyonu Kayıp ve Doğruluk Grafikleri



Şekil 9: Efficient-B0 Adadelta Optimizasyonu Karmaşıklık Matrisi

Tüm tablolar detaylı bir şekilde incelendiğinde transfer öğrenme modelleri için şu sonuçlar elde edilebilir;

- Veri setini 80-20 eğitim-test oranında ayırmak eğitim verisindeki örnek sayısını 70-30 eğitim-test oranına göre artırmış ve bu da modelin daha fazla örnekle öğrenmesini sağlayarak model başarımını olumlu etkilemiştir.
- Veri setini artırmak [ResNet-50](#), [EfficientNet-B0](#) ve [MobileNet-V2](#) modellerini olumlu etkilerken [VGG-19](#), [VGG-16](#) ve [DenseNet-121](#) modellerini olumsuz etkilemiştir. Bu

durum, bazı modellerin artırılmış veriden daha iyi genelleme yapabildiğini, bazılarının ise gürültüden daha fazla etkilendiğini göstermektedir.

- Optimizasyon algoritmaları karşılaştırıldığında, genel olarak en yüksek doğruluk ve F1-skor değerlerine **Nadam** algoritması ile ulaşılmıştır. Nadam algoritması, öğrenme oranını adaptif olarak güncelleyerek modelin daha hızlı ve istikrarlı şekilde yakınsamasını sağlamıştır. Bu algoritmayı sırasıyla **Adam**, **RMSprop**, Adadelata, **SGD** ve **Adagrad** takip etmektedir.
- Transfer öğrenme modelleri karşılaştırıldığında, genel olarak en yüksek doğruluk değerlerine ulaşan model **ResNet-50** olmuştur. Derin ve rezidüel yapısı sayesinde daha karmaşık desenleri öğrenebilme yeteneği, bu modelin diğerlerine kıyasla daha başarılı olmasını sağlamıştır. Bu modeli sırasıyla **EfficientNet-B0**, **VGG-19**, **VGG-16**, **DenseNet-121** ve **MobileNet-V2** takip etmektedir.

5.2 CNN'de Farklı Mimari ve Optimizasyonların Sınıflandırma Başarımına Etkisi

Bu bölümde, 32×32 , 64×64 , $32 \times 32 \times 32 \times 32$, $64 \times 64 \times 64 \times 64$ ve $32 \times 32 \times 64 \times 64$ şeklinde 5 farklı boyutta **CNN** tabanlı modellerin performansı, **Adam**, **Nadam**, **SGD** ve **RMSprop** optimizasyon yöntemleriyle analiz edilmiştir. **CNN** modelleri farklı optimizasyonlar ile hem orijinal hem de artırılmış ve hem 80-20 oranında hem de 70-30 oranında bölünen veri seti üzerinde ayrı ayrı değerlendirilmiştir. Değerlendirme, doğruluk, duyarlılık, kesinlik ve F1 Skoru metrikleri üzerinden yapılmıştır.

Model eğitimleri sonuçlarına göre Çizelge 14'te verilen 70-30 oranında bölünen orijinal veri seti ile yapılan deneyde en yüksek sonuç doğruluk metriğinde %99.17 başarı oranı ile $64 \times 64 \times 64 \times 64$ boyutunda **Nadam** optimizasyonu olmuştur. Çizelge 15'te verilen 80-20

oranında bölünen orijinal veri seti ile yapılan model eğitimleri sonucunda en yüksek sonuç neredeyse tüm metriklerde %100 başarı oranı ile 32x32 boyutunda **Nadam** optimizasyonu olmuştur. Aynı optimizasyonla 64x64x64x64 boyutundaki model ise %99.22 ile dikkat çekici bir başarı elde etmiştir. Ancak, her iki veri ayırımında da **SGD** diğer yöntemlere göre daha düşük sonuçlar vermiştir; örneğin, Çizelge 14’te 32x32x32x32 boyutunda %56, Çizelge 15’te ise %52 seviyesinde kalmıştır. Genel olarak **Nadam**, veri setinin her iki ayırım oranında da diğer yöntemlere üstünlük sağlamış ve öğrenme ile genelleme kapasitesi açısından daha başarılı sonuçlar sunmuştur.

Çizelge 14: 70-30 Oranında Bölünmüş Orijinal Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı

	Adam				Nadam				SGD				Rmsprop			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
32x32	0.9833	0.98	0.98	0.98	0.9839	0.98	0.98	0.98	0.9651	0.97	0.97	0.97	0.9786	0.98	0.98	0.98
64x64	0.9833	0.98	0.98	0.98	0.9839	0.98	0.98	0.98	0.8078	0.81	0.81	0.81	0.9818	0.98	0.98	0.98
32x32x32x32	0.9729	0.97	0.97	0.97	0.9719	0.97	0.97	0.97	0.5609	0.56	0.56	0.53	0.9573	0.96	0.96	0.96
32x32x64x64	0.9786	0.98	0.98	0.98	0.9849	0.98	0.98	0.98	0.5531	0.55	0.57	0.50	0.9771	0.98	0.98	0.98
64x64x64x64	0.9906	0.99	0.99	0.99	0.9917	0.99	0.99	0.99	0.5432	0.54	0.52	0.49	0.9818	0.98	0.98	0.98

Çizelge 15: 80-20 Oranında Bölünmüş Orijinal Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı

	Adam				Nadam				SGD				Rmsprop			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
32x32	0.9945	0.99	0.99	0.99	0.9961	1.00	1.00	1.00	0.9812	0.98	0.98	0.98	0.9953	1.00	1.00	1.00
64x64	0.9953	1.00	1.00	1.00	0.9922	0.99	0.99	0.99	0.9711	0.97	0.97	0.97	0.9914	0.99	0.99	0.99
32x32x32x32	0.9734	0.97	0.97	0.97	0.9867	0.99	0.99	0.99	0.5359	0.54	0.49	0.47	0.9719	0.97	0.97	0.97
32x32x64x64	0.9859	0.99	0.99	0.99	0.9938	0.99	0.99	0.99	0.5828	0.58	0.61	0.56	0.9766	0.98	0.98	0.98
64x64x64x64	0.9875	0.99	0.99	0.99	0.9852	0.99	0.99	0.99	0.5602	0.56	0.58	0.52	0.9867	0.99	0.99	0.99

Veri artırımı, özellikle **SGD** gibi düşük performanslı optimizasyon algoritmalarında doğruluk, duyarlılık, kesinlik ve F1 skoru gibi metrikleri belirgin şekilde iyileştirmiştir. Örneğin, Çizelge 14’te **SGD** ile 64x64 boyutunda elde edilen doğruluk oranı %80.78 iken, artırılmış veri kullanılan Çizelge 16’da bu oran %91.62’ye yükselmiştir. Ancak **Adam** ve **Nadam** gibi

güçlü optimizasyonlarla bazı durumlarda küçük performans düşüşleri gözlemlenmiştir. Örneğin, Çizelge 15’te Adam ile 64x64 boyutunda %99.53 doğruluk elde ederken, artırılmış veriye sahip Çizelge 17’de bu oran %99.25’e gerilemiştir. Bu veriler, veri artırımının özellikle düşük performanslı ayarlamalarda fayda sağladığını, ancak güçlü modellerde her zaman artış garantisi vermediğini ortaya koymaktadır.

Çizelge 16: 70-30 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı


	Adam				Nadam				SGD				Rmsprop			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
32x32	0.9833	0.98	0.98	0.98	0.9864	0.99	0.99	0.99	0.9432	0.94	0.95	0.94	0.9744	0.97	0.97	0.97
64x64	0.9713	0.97	0.97	0.97	0.9812	0.98	0.98	0.98	0.9250	0.93	0.93	0.93	0.9812	0.98	0.98	0.98
32x32x32x32	0.9614	0.96	0.96	0.96	0.9734	0.97	0.97	0.97	0.5281	0.53	0.43	0.46	0.9510	0.95	0.95	0.95
32x32x64x64	0.9781	0.98	0.98	0.98	0.9723	0.97	0.97	0.97	0.5604	0.56	0.56	0.53	0.9729	0.97	0.97	0.97
64x64x64x64	0.9895	0.99	0.99	0.99	0.9807	0.98	0.98	0.98	0.5515	0.55	0.55	0.55	0.9791	0.98	0.98	0.98

Çizelge 17: 80-20 Oranında Bölünmüş Artırılmış Veri Setinde Optimizasyonların CNN Üzerindeki Başarımı


	Adam				Nadam				SGD				Rmsprop			
	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru	Doğruluk	Duyarlılık	Kesinlik	F1 Skoru
32x32	0.9929	0.99	0.99	0.99	0.9937	0.99	0.99	0.99	0.9750	0.97	0.98	0.97	0.9945	0.99	0.99	0.99
64x64	0.9937	0.99	0.99	0.99	0.9875	0.99	0.99	0.99	0.9718	0.97	0.97	0.97	0.9906	0.99	0.99	0.99
32x32x32x32	0.9781	0.98	0.98	0.98	0.9820	0.98	0.98	0.98	0.5585	0.56	0.63	0.52	0.9820	0.98	0.98	0.98
32x32x64x64	0.9828	0.98	0.98	0.98	0.9875	0.99	0.99	0.99	0.5593	0.56	0.63	0.52	0.9890	0.99	0.99	0.99
64x64x64x64	0.9851	0.99	0.99	0.99	0.9796	0.98	0.98	0.98	0.5609	0.56	0.60	0.51	0.9835	0.98	0.98	0.98

Bu deney sonucunda en yüksek sonuç; doğruluk metriğinde %99.61 ve kesinlik, duyarlılık, f1 skoru metriklerinde ise %100 başarımla 80-20 oranında bölünmüş ve orijinal veri seti kullanılarak yapılan model eğitimi sürecinde 32x32 boyutu ile Nadam optimizasyonu olmuştur. Şekil 10’da bu sonuca ait doğruluk ve kayıp grafiği verilmiş olup, eğitim ve doğrulama doğruluğu yaklaşık 5. epoch’tan itibaren %90’ın üzerine çıkarak birbirine çok yakın seyrettiği görülmektedir. Bu da modelin aşırı öğrenme yapmadığını göstermektedir. Benzer şekilde eğitim ve doğrulama kaybı da hızlı bir şekilde düşerek düşük seviyelerde

sabitlenmiş ve iki eğri arasındaki fark oldukça az kalmıştır. Bu durum modelin dengeli bir şekilde öğrenme gerçekleştirdiğini ortaya koymaktadır. Şekil 11'deki en iyi sonuca ait karmaşıklık matrisi ise modelin sınıflar arasında yüksek doğrulukla tahminler yaptığını ve yanlış sınıflandırmaların oldukça düşük seviyede gerçekleştiğini ortaya koymaktadır. Genel olarak model, hem eğitim sürecinde hem test aşamasında yüksek performans sergileyerek sınıfları başarıyla ayırt edebilmiştir.



Şekil 10: CNN (32x32) - Nadam Doğruluk ve Kayıp Grafikleri



Şekil 11: CNN (32x32) - Nadam Karmaşıklık Matrisi

5.3 Önceki Çalışmalar ile Kıyaslama

Bu çalışmada kullanılan yöntemler, literatürdeki benzer çalışmalar ile karşılaştırıldığında önemli farklılıklar ve katkılar içermektedir. Öncelikle, Alzheimer hastalığı dört sınıfta ele alınmıştır. Literatürde yer alan birçok çalışmada sınıflandırmalar genellikle ikili ya da üçlü düzeyde yapılmakta olup, dört sınıf içeren ayrıntılı sınıflandırmalara sınırlı sayıda çalışmada rastlanmaktadır. Literatürde yaygın olarak kullanılan CNN dışında, altı farklı transfer öğrenme mimarisi kapsamlı değerlendirilmiştir. Literatürde çoğu çalışmanın yalnızca bir veya iki mimari üzerinde durduğu, bazı çalışmaların ise belirli bir modele odaklandığı görülmektedir. Örneğin, yalnızca VGG-19 veya ResNet-50 kullanılan çalışmaların sayısı oldukça fazladır. Ancak bu çalışmada tüm mimariler birlikte değerlendirilmiştir. Sınıflandırma mimarileri dışında optimizasyon fonksiyonları açısından da çeşitlilik sağlanmıştır. Çalışmada toplam altı farklı optimizasyon fonksiyonları kullanılarak model başarımları karşılaştırılmıştır. Literatürde genellikle tek bir optimizasyon algoritmasına (çoğunlukla Adam'a) yer verilmiştir. Performans değerlendirme sürecinde çok sayıda metrik kullanılarak modellerin başarımları kapsamlı şekilde analiz edilmiştir. Ayrıca veri seti üzerinde hem %70-%30 ve %80-%20 oranlarında eğitim-test ayrımı yapılmıştır. Her iki bölünme için hem orijinal hem de verilerin artırılmış versiyonları üzerinde değerlendirilmiştir. Literatürde çalışmaların büyük çoğunluğu yalnızca tek oranlı bölünme ile sınırlı kalmış ve artırılmış verilerle yapılan çok yönlü analizlere nadiren rastlanılmıştır. Tüm bu yönleriyle çalışma, literatürdeki pek çok çalışmaya kıyasla daha geniş kapsamlı, parametrik çeşitlilik içeren ve çok boyutlu bir analiz imkânı tanımıştır. Çizelge 18'de aynı veri setini kullanan literatürdeki diğer çalışmalar, kullanılan modellerle kıyaslanmıştır.

Çizelge 18: Literatürle Başarım Karşılaştırılması

Araştırmacılar	Kullanılan Modeller	Performans Metrikleri	Başarım
Das vd.	VGG-19, ResNet-50, Xception, InceptionV3	MCC, Dengeli Doğruluk Skoru	%89
Demir	MobileNetV2, VGG16,	Duyarlılık	%89
Adhora vd.	CNN, InceptionV3, ResNet50	Duyarlılık	%95
Jayanthi vd.	VGG-16	Doğruluk, Hassasiyet, Geri Çağırma, F1 Skoru	%98.80
Mamun vd.	CNN, VGG-16, Resnet-101, DenseNet-121	Doğruluk, ROC, Geri Çağırma	%97.60 %99.17
Pallawi ve Singh	EfficientNetB0	Doğruluk, Hassasiyet, Duyarlılık, F1 Skoru	%95.78
Mujahid vd.	CNN, DenseNet-121, EfficientNet-B2, VGG-16, Xception	Doğruluk, AUC	%90.50
Pradhan vd.	CNN, DenseNet, ResNet-50, VGG, EfficientNet	Doğruluk, Kesinlik, Duyarlılık, F1 Skoru	%95.45
Fahmi Khalifa vd.	CNN	Doğruluk, Duyarlılık, Özgüllük, ROC-AUC	%96.69
Velid El Şehrisi	DenseNet-19, ResNet-50	Doğruluk, ROC- AUC	%81.98
Bu Çalışma	CNN, ResNet-50, VGG-16, VGG-19, DenseNet-121, MobileNet-V2, EfficientNet-B0	Doğruluk, Duyarlılık, Kesinlik, F1 Skoru	%99.61

5.4 Sonuç ve Yorum

Bu çalışmada Alzheimer hastalığının farklı evreleri **MR** görüntüleri üzerinden sınıflandırılması hedeflenmiştir. Bu amaçla derin öğrenme tabanlı **CNN** mimarileri kullanılmış, farklı transfer öğrenme yöntemleri ve optimizasyon teknikleri, orijinal ve artırılmış veri ile farklı bölünme oranlarıyla sistematik olarak karşılaştırılmıştır. Tüm sonuçlar göz önünde bulundurulduğunda en başarılı sonuç olarak; **CNN** modelinde doğruluk metriği ile %99.61 ve kesinlik, duyarlılık ve f1 skoru metriği ile %100 başarımları elde edilmiştir.

Çalışmadaki sonuçlar şu şekilde sıralanabilir:

- **Eğitim-Test Bölünme Oranının Katkısı**

%80 eğitim – %20 test oranı ile yapılan deneyler genel olarak daha başarılı sonuçlar üretmiştir. Bu oran modelin öğrenmesi için daha fazla veri sunduğundan dolayı daha iyi genelleme sağlamış, test verisi üzerindeki başarıyı artırmıştır. %70 eğitim – %30

test oranı ise bazı durumlarda yeterli olsa da %80 eğitim – %20 test oranı daha istikrarlı bir başarı sunmuştur.

- **Veri Artırmanın Etkisi**

Yapılan çalışmada veri artırma uygulaması, bazı mimarilerde belirgin başarı artışı sağlarken bazı güçlü mimarilerde ise performans düşüşlerine neden olmuştur. Örneğin, [ResNet-50](#) + [RMSprop](#) kombinasyonu, %70 %30 eğitim oranı ile çalıştırılan artırılmış veri setinde doğruluk oranı %96.09'dan %97.86 oranına ulaşmıştır. Buna karşılık, [EfficientNet-B0](#) + Adadelta kombinasyonu, orijinal veri setinde %80 - %20 eğitim oranı ile çalıştırıldığında %99.14 doğruluk elde edilirken, veri artırma sonrası bu başarı ciddi bir düşüş yaşayarak %18.67 doğruluğuna ulaşmıştır.

- **Optimizasyon Algoritmalarının Etkisi**

Çalışmada en başarılı sonuçlar [Nadam](#) ve [Adam](#) fonksiyonlarıyla elde edilmiştir. Özellikle [Nadam](#) fonksiyonu ile, [ResNet-50](#) mimarisinde %99.37 doğruluk oranına ulaşarak dikkat çekmiştir. [SGD](#) ise daha düşük doğruluk ve F1 skorlarıyla sınırlı kalmıştır; bu da karmaşık ağlarda lokal minimumlara sıkışma eğilimini ve hiperparametre duyarlılığını ortaya koymaktadır.

- **Transfer Öğrenme Mimarilerinin Karşılaştırılması**

Transfer öğrenme modelleri üzerinde yapılan deneylerde, [ResNet-50](#) ve [EfficientNet-B0](#) genel olarak en başarılı sonuçları vermiştir. Örneğin Çizelge 8'de [ResNet-50](#) + [Nadam](#) kombinasyonu tüm metriklerde %98.50 üzerinde performans gösterirken [EfficientNet-B0](#) modeli ise %97.73 doğruluk oranıyla ikinci sırada yer almıştır.

- **CNN Mimarilerinin Karşılaştırılması**

Mimari derinlik ve katman kombinasyonları (örneğin 32x32, 64x64, 32x32x64x64,

64x64x64x64) başarı üzerinde etkili olmuştur. 32x32 mimarisi, özellikle **Nadam** optimizasyon fonksiyonu ile birlikte kullanıldığında doğruluk metriği açısından %99.61 gibi yüksek bir başarıya ulaşmıştır. Katman sayısının artması, modelin öğrenme kapasitesini artırmış ancak **SGD** gibi zayıf optimizasyonlarla bu artışın sınırlı kaldığı gözlemlenmiştir.

Genel Yorum

Bu çalışma, Alzheimer hastalığının farklı evrelerinin **MR** görüntülerinden sınıflandırılmasında **DL** yöntemlerinin yüksek başarı sağladığını göstermektedir. Özellikle veri artırma, doğru optimizasyon seçimi ve uygun **CNN** mimarisi kombinasyonunun kullanımı, sınıflandırma performansını doğrudan artırmaktadır. En başarılı sonuçlar, **CNN** modelinde doğruluk metriği ile %99.61 ve kesinlik, duyarlılık ve f1 skoru metriği ile %100 olarak elde edilmiştir.

Bu sonuçlar doğrultusunda geliştirilecek tıbbi karar destek sistemlerinde bu tür **DL** temelli yaklaşımların kullanılarak, hastalığın erken evrede tespitinde doktorlara yardımcı olabilmesi umudunu taşımaktayız. Gelecekte, gerçek zamanlı sistemlerde çalışabilecek daha hafif modeller ve daha dengeli veri setleriyle modelin doğruluğu ve güvenilirliği daha da artırılabilir.

KAYNAKÇA

- [1] M Venkatd Dasu, C Priyanka, G Tejaswini, J Venkata Ramana, D Suleman, and S Tharun Sai. Classification of alzheimer disease using machine learning algorithm. In *2024 International Conference on Automation and Computation (AUTOCOM)*, pages 215–221. IEEE, 2024.
- [2] Mehmet Emre Sertkaya and Burhan Ergen. Alzheimer hastalığının teşhisinde görüntü dönüştürücü (vision transformer) yaklaşımı: Yenilikçi bir İnceleme. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 36(2):609–619, 2024.
- [3] Tulip Das, Chinmaya Kumar Nayak, and Parthasarathi Pattnayak. Mri image-based advanced transfer learning and machine learning architectures for classifying alzheimer’s disease. In *2024 Second International Conference on Intelligent Cyber Physical Systems and Internet of Things (ICoICI)*, pages 967–973. IEEE, 2024.
- [4] Vrashikesh Patil and SL Nisha. Detection of alzheimer’s disease using machine learning and image processing. In *2021 International Conference on Smart Generation Computing, Communication and Networking (SMART GENCON)*, pages 1–5. IEEE, 2021.
- [5] Rigel Mahmood and Bishad Ghimire. Automatic detection and classification of alzheimer’s disease from mri scans using principal component analysis and artificial neural

- networks. In *2013 20th International Conference on Systems, Signals and Image Processing (IWSSIP)*, pages 133–137. IEEE, 2013.
- [6] Sumit Salunkhe, Mrinal Bachute, Shilpa Gite, Nishad Vyas, Saanil Khanna, Keta Modi, Chinmay Katpatal, and Ketan Kotecha. Classification of alzheimer’s disease patients using texture analysis and machine learning. *Applied System Innovation*, 4(3):49, 2021.
- [7] Fatemah H Alghamedy, Muhammad Shafiq, Lijuan Liu, Affan Yasin, Rehan Ali Khan, and Hussien Sobahi Mohammed. Machine learning-based multimodel computing for medical imaging for classification and detection of alzheimer disease. *Computational Intelligence and Neuroscience*, 2022(1):9211477, 2022.
- [8] N Komal Kumar, VD Ambeth Kumar, Danish Quamar, B Sumanth Kumar Reddy, R Yogendra, and N Poojitha. Enhanced alzheimer’s disease prediction through advanced imaging: A study of machine learning and deep learning approaches. In *2024 5th International Conference on Smart Electronics and Communication (ICOSEC)*, pages 1177–1182. IEEE, 2024.
- [9] Simeon Yuda Prasetyo. Alzheimer’s disease identification through brain mri images: Leveraging pretrained cnn models. In *2024 IEEE 10th International Conference on Smart Instrumentation, Measurement and Applications (ICSIMA)*, pages 321–325. IEEE, 2024.
- [10] Gokce Uysal and Mahmut Ozturk. Using machine learning methods for detecting alzheimer’s disease through hippocampal volume analysis. In *2019 Medical Technologies Congress (TIPTEKNO)*, pages 1–4. IEEE, 2019.

- [11] KC Veena, Mrs R Kavi Priya, and D Sumathi. Predictive diagnostic analysis for early detection of alzheimer's disease using machine learning. *Journal of Algebraic Statistics*, 13(1):586–592, 2022.
- [12] Fatih Demir. Detection of alzheimer's disease with a deep learning-based approach from mr images. In *International Sciences and Innovation Congress*. ISARC, 2021.
- [13] Kota Oishi, Hiroki Fuse, Norihide Maikusa, Tadanori Fukami, Japanese Alzheimer's Disease Neuroimaging Initiative, et al. Classification of patients with alzheimer's disease and healthy subjects from mri brain images using the existence probability of tissue types. In *2018 Joint 10th International Conference on Soft Computing and Intelligent Systems (SCIS) and 19th International Symposium on Advanced Intelligent Systems (ISIS)*, pages 1035–1038. IEEE, 2018.
- [14] Nazifa Rahman Adhora, Shyla Afroge, Kollol Kumar, and Mir Safwan Marzouq. Deep learning based feature fusion model for classifying alzheimer's disease using brain mri images. In *2023 26th International Conference on Computer and Information Technology (ICCIT)*, pages 1–6. IEEE, 2023.
- [15] M Bharath, S Gowtham, S Vedanth, Ashwini Kodipalli, Trupthi Rao, and BR Rohini. Predicting alzheimer's disease progression through machine learning algorithms. In *2023 International Conference on Recent Advances in Science and Engineering Technology (ICRASET)*, pages 1–5. IEEE, 2023.
- [16] Ruchika Das and Shobhanjana Kalita. Classification of alzheimer's disease stages through volumetric analysis of mri data. In *2022 IEEE Calcutta Conference (CALCON)*, pages 165–169. IEEE, 2022.

- [17] P Jayanthi, S Sharath, N Sri Sanjai, and A Thamiz Selvan. Enhanced method for identification of alzheimer's disease using deep learning. In *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, pages 1–7. IEEE, 2024.
- [18] Muntasir Mamun, Siam Bin Shawkat, Md Salim Ahammed, Md Milon Uddin, Md Ishtyaq Mahmud, and Asm Mohaimenul Islam. Deep learning based model for alzheimer's disease detection using brain mri images. In *2022 IEEE 13th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON)*, pages 0510–0516. IEEE, 2022.
- [19] Shruti Pallawi and Dushyant Kumar Singh. Detection of alzheimer's disease stages using pre-trained deep learning approaches. In *2023 IEEE 5th International Conference on Cybernetics, Cognition and Machine Learning Applications (ICCCMLA)*, pages 252–256. IEEE, 2023.
- [20] Jia Xian Fong, Mohd Ibrahim Shapiai, Yuan You Tiew, Uzma Batool, and Hilman Fauzi. Bypassing mri pre-processing in alzheimer's disease diagnosis using deep learning detection network. In *2020 16th IEEE International colloquium on signal processing & its applications (CSPA)*, pages 219–224. IEEE, 2020.
- [21] Shreyan Kancharla. Integrating traditional machine and deep learning methods for enhanced alzheimer's detection from mri images. In *2024 IEEE International Conference on Information Reuse and Integration for Data Science (IRI)*, pages 290–295. IEEE, 2024.
- [22] Muhammad Mujahid, Amjad Rehman, Teg Alam, Faten S Alamri, Suliman Mohamed Fati, and Tanzila Saba. An efficient ensemble approach for alzheimer's disease detection

- using an adaptive synthetic technique and deep learning. *Diagnostics*, 13(15):2489, 2023.
- [23] Nilanjana Pradhan, Shrdhha Sagar, and Ajay Shankar Singh. Analysis of mri image data for alzheimer disease detection using deep learning techniques. *Multimedia Tools and Applications*, 83(6):17729–17752, 2024.
- [24] Janani Venugopalan, Li Tong, Hamid Reza Hassanzadeh, and May D Wang. Multimodal deep learning models for early detection of alzheimer’s disease stage. *Scientific reports*, 11(1):3254, 2021.
- [25] Qing Zhao, Hanrui Xu, Jianqiang Li, Faheem Akhtar Rajput, and Liyan Qiao. The application of artificial intelligence in alzheimer’s research. *Tsinghua Science and Technology*, 29(1):13–33, 2023.
- [26] Marwa EL-Geneedy, Hossam El-Din Moustafa, Fahmi Khalifa, Hatem Khater, and Eman AbdElhalim. An mri-based deep learning approach for accurate detection of alzheimer’s disease. *Alexandria Engineering Journal*, 63:211–221, 2023.
- [27] Emtiaz Hussain, Mahmudul Hasan, Syed Zafrul Hassan, Tanzina Hassan Azmi, Md Anisur Rahman, and Mohammad Zavid Parvez. Deep learning based binary classification for alzheimer’s disease detection using brain mri images. In *2020 15th IEEE Conference on Industrial Electronics and Applications (ICIEA)*, pages 1115–1120, 2020.
- [28] Waleed Al Shehri. Alzheimer’s disease diagnosis and classification using deep learning techniques. *PeerJ Computer Science*, 8:e1177, 2022.
- [29] Sundus Munir M. A. Khan Munir Ahmad Ghassan F. Issa Syeda Binish Zahra Muhammad Adnan Khan Mohammad Kamrul Hasan Taher M. Ghazal, Sagheer Abbas.

Alzheimer disease detection empowered with transfer learning. *Computers, Materials & Continua*, 70(3):5005–5019, 2022.

- [30] Cansu Akyürek Anacur, Asuman Günay Yilmaz, and Murat Aykut. Handwriting analysis for alzheimer’s diagnosis: Feature enrichment and machine learning classification. In *2024 8th International Artificial Intelligence and Data Processing Symposium (IDAP)*, pages 1–5. IEEE, 2024.
- [31] Python Software Foundation. Python Programming Language - Official Website. <https://www.python.org>.
- [32] Google Research. Google colaboratory. <https://colab.research.google.com>.
- [33] Uraninjo. Augmented alzheimer mri dataset. <https://www.kaggle.com/datasets/uraninjo/augmented-alzheimer-mri-dataset>, 2023.